



南京大學

本科畢業設計

院 系 匡亞明學院

專 業 計算機科學與技術(腦科學與人工智能)

題 目 元學習視角下的預訓練策略

與強化學習在線微調

年 級 2022 學 號 221240035

學生姓名 李想

指導教師 趙鵬 職 稱 副教授

提交日期 2026 年 5 月 20 日



南京大学本科毕业论文（设计） 诚信承诺书

本人郑重承诺：所呈交的毕业论文（设计）（题目：元学习视角下的预训练策略与强化学习在线微调）是在指导教师的指导下严格按照学校和院系有关规定由本人独立完成的。本毕业论文（设计）中引用他人观点及参考资源的内容均已标注引用，如出现侵犯他人知识产权的行为，由本人承担相应法律责任。本人承诺不存在抄袭、伪造、篡改、代写、买卖毕业论文（设计）等违纪行为。

作者签名：

学号：

日期：

南京大学本科生毕业论文（设计、作品）中文摘要

题目：元学习视角下的预训练策略与强化学习在线微调

院系：匡亚明学院

专业：计算机科学与技术（脑科学与人工智能）

本科生姓名：李想

指导教师（姓名、职称）：赵鹏 副教授

摘要：

近年来，大语言模型通常采用“预训练—后训练”的两阶段范式：先通过大规模下一词元预测获得基础能力，再通过 RLHF 或 RLVR 等强化学习后训练提升模型在推理、对话和复杂任务中的表现。现有研究多从初始化质量、“覆盖”或高奖励轨迹概率的角度解释这一有效性，但这一视角难以完全说明为什么初始性能相近的基础模型在强化学习微调后可能表现出不同的提升。本文从元学习视角重新理解预训练与后训练过程，认为任务结构化预训练数据可以使下一词元预测成为一种隐式元训练过程，使模型通过上下文推断当前任务并形成快速适应机制；而强化学习后训练不仅可以提高已有高奖励轨迹的采样概率，也可能进一步优化这种适应机制。本文在理论部分定义刻画“元适应”能力的指标，并结合类似 $\text{pass}@k$ 的“覆盖”分析实验，比较基础模型与强化学习后训练模型在“覆盖”、采样效率和“元适应”能力上的差异。本文的核心观点是：预训练不仅提供静态知识和初始策略，还可能赋予模型快速适应机制；强化学习后训练则不仅是输出概率调整，也可能进一步塑造这种机制。

关键词：大语言模型；元学习；预训练；强化学习；上下文学习；覆盖

南京大学本科生毕业论文（设计、作品）英文摘要

THESIS: Pre-training and Online RL Fine-tuning: A Meta-Learning Perspective

DEPARTMENT: Kuang Yaming Honors School

SPECIALIZATION: Computer Science and Technology (Brain Science and Artificial Intelligence)

UNDERGRADUATE: Xiang Li

MENTOR: Assistant Professor Peng Zhao

ABSTRACT:

Large language models are commonly trained through a two-stage paradigm: large-scale next-token pretraining followed by reinforcement-learning-based post-training, such as RLHF or RLVR, to improve their performance on reasoning, dialogue, and complex tasks. Existing explanations often emphasize initialization quality, coverage, or the probability mass assigned to high-reward trajectories, but this view does not fully explain why base models with similar initial performance may exhibit different gains after reinforcement learning fine-tuning. This thesis revisits pretraining and post-training from a meta-learning perspective. We argue that next-token prediction on task-structured data can be understood as an implicit meta-training process, where the model learns to infer the current task from context and thereby acquires a mechanism for fast adaptation. From this perspective, reinforcement learning post-training not only increases the sampling probability of existing high-reward trajectories, but may also further optimize this adaptation mechanism. The thesis introduces metrics for measuring meta-adaptation and conducts $\text{pass}@k$ -style coverage analysis to compare base and RL-post-trained models in terms of coverage, sampling efficiency, and meta-adaptation. The central claim is that pretraining provides not only static knowledge and an initial policy, but also a fast adaptation mechanism that reinforcement learning post-training may further shape.

KEYWORDS: Large Language Models; Meta Learning; Pre-training; Reinforcement Learning; In-Context Learning; Coverage

目 录

目 录	V
第一章 绪论	1
1.1 研究背景	1
1.2 研究问题与核心观点	4
1.3 本文主要内容与贡献	4
第二章 相关工作	7
2.1 大语言模型的预训练与上下文学习	7
2.2 元学习与元强化学习	8
2.3 离线到在线强化学习与策略微调	8
2.4 大语言模型的强化学习后训练	9
第三章 预训练的元学习解释与理论分析	11
3.1 任务结构化预训练与隐式元训练	11
3.2 预训练模型作为上下文元学习器	13
3.3 线性分类中的元学习理论	15
3.4 线性回归中的元学习理论	19
第四章 强化学习后训练中的“覆盖”与“元适应”	21
4.1 大语言模型后训练作为在线策略微调及“覆盖”解释	22
4.2 强化学习后训练作为元学习器的外层优化	24
4.3 “覆盖”增益与“元适应”增益的理论分解	27
4.4 实验设计与结果分析	31
第五章 总结与展望	39

5.1 本文工作总结	39
5.2 局限性与未来展望	40
参考文献	43
致 谢	47
附录 A 正文中定理的证明	49
A.1 第 3.2 节中定理/命题的证明	49
A.2 第 3.3 节中定理/命题的证明	51
A.3 第 3.4 节中的定理/命题的证明	54
A.4 第 4.2 节中定理/命题的证明	56
A.5 第 4.3 节中定理/命题的证明	57
附录 B 正文中涉及的数据及源代码	61
B.1 数据来源与三类条件	61
B.2 Prompt 构造	62
B.3 评估代码与运行参数	63
B.4 输出文件与指标整理	64

第一章 绪论

1.1 研究背景

近年来，大语言模型（Large Language Models, LLMs）已经逐渐形成了较为稳定的训练范式：首先在大规模文本语料上进行预训练（pre-training），使模型获得通用的语言建模能力、知识表达能力和一定的推理能力；随后再通过指令微调、基于人类反馈的强化学习（RLHF）或基于可验证奖励的强化学习（RLVR）等后训练（post-training）方法，使模型更加符合人类偏好，并在数学、代码、问答和复杂推理任务上取得更好的表现。与传统机器学习中针对单一任务训练模型的方式不同，大语言模型的预训练通常采用下一词元预测（next-token prediction）目标，即让模型根据前文预测产生下一个词元（token）。这个目标看似简单，却在足够大的模型、数据和计算规模下产生了非常丰富的能力。GPT-3 的少样本学习（few-shot learning）现象表明，模型在没有显式梯度更新的情况下，也可以通过上下文中的少量示例完成新任务^[1]。这使得研究者开始意识到，大语言模型并不只是记忆训练数据中的统计规律，而是可能在某种程度上学会了如何利用上下文进行任务适应。

在预训练之后，强化学习（Reinforcement Learning, RL）后训练，又称作“在线强化学习微调”（online RL fine-tuning），进一步成为提升大语言模型能力的重要步骤。早期的 RLHF 工作主要关注如何使大语言模型更符合人类偏好，例如让模型生成更有帮助、更安全、更符合指令的回答^[2]。近年来，随着数学推理和代码生成任务的重要性上升，RLVR 受到越来越多关注。在这类任务中，模型输出是否正确可以通过程序、数学答案或形式化规则进行验证，因此强化学习可以直接利用可验证奖励来优化模型行为。DeepSeekMath 和 DeepSeek-R1 等工作显示，在强预训练模型之上进行强化学习，可以显著提升模型的推理表现，并诱导出自我反思、验证和更长推理链等行为^[3-4]。这些结果使得很多人自然地认为，强化学习可能是推动大语言模型推理能力继续增长的关键机制。

然而，强化学习在后训练中究竟“创造”了什么能力，仍然是一个尚未完全清楚的问题。近期一些研究开始对 RLVR 的作用提出了更加谨慎的解释。例如 Chen et al.^[5] 从 $\text{pass}@k$ 角度分析 RL 模型与基模型（base model）的差异。他们发现，强化学习模型通常在较小的 k ，尤其是 $\text{pass}@1$ 上表现更好；但当 k 足够大时，基模型有时能够采样到与强化学习模型相当、甚至更多的正确解。这说明，强化学习带来的提升未必总是来自全新推理能力的产生，而可能主要来自对已有正确轨迹的概率重分配：基模型本来就有一定概率生成正确推理路径，RLVR 只是提高了这些路径在采样分布中的权重，使模型在较少采样次数下更容易给出正确答案。这一观点与“覆盖”（coverage）的解释是一致的，即预训练模型如果已经对高质量答案或轨迹赋予了足够概率质量，那么后训练就可以通过偏好优化（preference optimization）或奖励优化（reward optimization）放大这些行为。

这种解释非常重要，因为它避免了对强化学习作用的过度神秘化。但另一方面，仅仅从“覆盖”或采样效率出发，似乎也不能完全解释所有现象。现实中，我们经常看到一些初始准确率相近的模型，在经过类似的后训练之后，提升幅度并不相同；有些模型可以迅速从少量反馈中受益，而另一些模型虽然也能生成正确答案，却很难稳定地把这种能力转化成可持续的性能提升。如果强化学习只是简单地提高已有正确答案的概率，那么这些差异就并不容易解释。换句话说，除了“模型有没有覆盖正确轨迹”之外，我们还需要进一步解释：模型是否能够根据上下文（context）、反馈和历史经验快速调整自己的行为？它是否已经在预训练中形成了一种可被后训练利用的适应机制？

这正是元学习（meta-learning）视角进入大语言模型研究的地方。元学习通常被概括为“学习如何学习”（learning-to-learn）。在经典的元学习设定中，模型并不是只学习一个固定任务，而是在许多相关任务上训练，从而在遇到新任务时能够利用少量样本快速适应。例如，经典的 MAML 算法通过优化一个适合快速梯度更新的初始化来实现这一点^[6]；RL² 算法则用循环神经网络（RNN）把一个快速强化学习算法编码在模型的隐藏状态（latent state）中，使模型在新的环境中通过历史交互逐步调整策略^[7]。这些工作虽然诞生于前大语言模型时代，但其核心思想与现在的大语言模型有很强的联系：如果训练数据本身包含大量相关但不完全相同的任务，那么模型可能并不只是学习每个任务的答案，而是在学习如何从少量信息中识别任务结构，并据此改变预测或决策方式。

从这个角度看，下一词元预测与元学习之间存在天然联系。语言数据并非完全独立同分布的词元序列，而是蕴含着丰富的隐式任务结构：对话有特定意图和背景，文章有主题与写作规范，数学题有条件与目标。模型在预测下一个词元时，需要根据上下文判断当前任务、匹配合适风格、调用相关知识，并决定推理的下一步。因此，预训练可被视为一种隐式的元训练（meta training）过程：上下文提供当前任务的信息，而后续词元预测则要求模型将这些信息转化为具体输出。近期关于上下文学习（in-context learning）和 transformer 元学习能力的理论工作，也逐渐支持这种理解。例如，一些研究将上下文学习解释为隐式贝叶斯推断^[8]，另一些工作则在共享低维结构的线性分类任务中证明，经过训练的 transformer 可以像一个接近最优的元学习器（meta-learner）一样，在新任务上只依赖少量上下文样本完成适应（详见第 3.3 节）^[9]。

在此基础上，强化学习后训练也可以被重新理解。如果预训练模型已经不是一个普通的静态策略，而是一个具有快速适应能力的元学习器，那么 RLHF 或 RLVR 的作用就不仅仅是调整输出概率。它当然可以提高高奖励轨迹的采样概率，这是“覆盖”视角已经强调的部分；但它也可能进一步影响模型如何利用上下文和反馈，如何选择推理策略，如何在能力边界附近进行调整。也就是说，强化学习后训练可以被看做作用在预训练所得适应机制之上的外层优化。它优化的不只是“回答什么”，还可能包括“如何根据新的信息改变回答方式”。

因此，本文试图把预训练和强化学习后训练放在同一个元学习框架下理解：预训练阶段可能是模型在海量任务结构中学到一种基于上下文的快速适应机制；在线强化学习微调则在奖励反馈下进一步塑造这种机制，并改变模型在“覆盖”、采样效率和适应能力之间的平衡。这一视角并不否认“覆盖”解释的重要性，而是希望在“覆盖”之外补充一个关于“适应能力”的解释维度。对于当前大语言模型相关研究工作大量涌现的背景而言，这种探索性工作具有一定意义：它不只是问强化学习有没有提升最终分数，而是进一步追问这种提升究竟来自有能力概率放大，还是来自模型对新任务和新反馈的适应方式发生了变化。围绕这一问题展开分析，有助于更清楚地理解大语言模型两阶段训练范式的内在机制，也可能为未来设计更高效、更稳定的后训练方法提供参考。

1.2 研究问题与核心观点

在第 1.1 节中已经讨论了大语言模型两阶段训练范式的背景，以及强化学习后训练（也即“在线强化学习微调”）作用机制中的一些争议。本文关心的问题并不是简单判断强化学习后训练是否“有用”，因为从大量经验结果来看，RLHF 和 RLVR 确实能够在许多任务上提升模型表现。更关键的问题在于：这种提升究竟来自哪里？它只是提高了模型采样到已有正确答案的概率，还是也改变了模型根据上下文和反馈进行快速适应的方式？进一步地，如果强化学习后训练的效果依赖于预训练模型本身，那么预训练阶段到底为后续强化学习提供了什么样的基础？

围绕这一问题，本文试图从元学习角度重新理解大语言模型的预训练和强化学习后训练。具体来说，本文将预训练模型看作一个在大规模任务结构中训练得到的元学习器。它并不只是根据固定参数完成预测，而是在给定上下文之后，能够隐式推断当前任务的结构，并据此调整输出。基于这一理解，强化学习后训练也可以被看作对这种上下文适应机制的进一步优化，而不仅仅是对输出概率分布的局部调整。

本文的核心观点是：

预训练可能使大语言模型获得一种基于上下文的快速适应机制，
而强化学习后训练则可能在奖励反馈下进一步利用和塑造这种机制。

1.3 本文主要内容与贡献

本文围绕“预训练—强化学习后训练”这一大语言模型训练范式，从元学习角度展开分析。主要内容和贡献包括以下几个方面：

- **提出一个统一的元学习解释视角。** 本文将大语言模型的预训练理解为一种隐式元训练过程：当训练数据中存在任务结构时，下一词元预测不只是学习词元的局部统计规律，也会促使模型学习如何利用上下文推断当前任务。基于这一点，本文进一步将强化学习后训练理解为作用在已有适应机制之上的外层优化过程，从而把预训练、上下文学习和强化学习后训练联系起来。

- **讨论预训练模型为何可以表现出元学习能力。**本文从任务结构化数据出发，分析自回归预训练如何诱导模型形成上下文依赖的预测规则。随后结合线性分类和线性回归中的共享结构模型，说明当不同任务共享某种低维结构时，预训练模型可以通过学习这种结构降低新任务上的适应难度。这一部分为“预训练模型作为元学习器”的观点提供理论支持。
- **区分强化学习后训练中的“覆盖”增益与“元适应”增益。**针对 RLVR 是否真正扩展模型能力这一问题，本文认为仅观察最终准确率并不足够。强化学习可能只是提高已有高奖励轨迹的采样概率，也可能改善模型利用新上下文和新反馈的能力。为此，本文将在理论部分引入刻画“元适应”能力的指标，并将其与类似 $\text{pass}@k$ 的“覆盖”指标进行比较。
- **设计以强化学习后训练为核心的实验分析。**实验部分（第 4.4 节）主要关注强化学习前后模型在“覆盖”、采样效率和“元适应”能力上的变化。通过比较基模型与经过强化学习训练的模型在不同采样预算和不同适应设定下的表现，本文希望分析强化学习后训练的收益在多大程度上可以由“覆盖”解释，以及是否存在超出“覆盖”之外的适应能力变化。

总体而言，本文的目标不是提出一个完整的新训练算法，而是从理论和实验两个层面探索一种理解大语言模型训练机制的角度，在已有大量大语言模型相关经验研究的基础上，尝试把预训练、上下文学习和强化学习后训练放到同一个元学习视角下重新审视。

本文共分为五章。第一章介绍基本背景和本文主要内容；第二章回顾与本文相关的研究工作；第三章从元学习角度分析预训练的作用；第四章进一步讨论强化学习后训练的作用机制，并给出实验设计和结果分析；第五章总结全文。此外，附录中给出正文中定理的证明（附录 A）以及相关数据和代码说明（附录 B）。

第二章 相关工作

2.1 大语言模型的预训练与上下文学习

大语言模型在实践中通常首先通过大规模自监督预训练 (self-supervised pre-training) 获得基础能力, 其中最典型的是自回归语言模型中的下一词元预测。虽然这一目标形式上只是根据前文预测下一个词元, 但在足够大的模型、数据和计算规模下, 它逐渐表现出远超传统语言建模的能力。GPT-3 展示了模型在不进行参数更新的情况下, 仅通过自然语言指令或少量输入输出示例, 就能完成翻译、问答、分类和简单推理等任务^[1]。这一现象使“上下文学习”成为理解大语言模型能力来源的重要问题。上下文学习指的是模型在推理阶段根据 prompt 中的示例、说明或交互历史调整输出, 而模型参数本身保持不变。早期经验研究表明, 上下文学习并不只是从少量示例中拟合一个输入输出映射; 例如 Min et al.^[10] 发现, 即使打乱示例标签, 模型在一些任务上的性能也不一定显著下降, 说明上下文还提供了任务格式、输入分布、输出空间和语义风格等信息。Xie et al.^[8] 则从隐式贝叶斯推断角度解释上下文学习, 认为模型在具有长程一致性的预训练文本中学会了根据上下文推断潜在概念或任务, 这一观点也自然支持了“预训练可能诱导任务识别能力”的理解。

近几年的理论研究进一步将上下文学习与“学习算法”联系起来。Garg et al.^[11] 系统研究了 transformer 在简单函数类上的上下文学习能力, 发现其可以从上下文中学习线性函数、稀疏线性函数和决策树等任务。Akyürek et al.^[12] 和 Von Oswald et al.^[13] 等工作进一步指出, 在一些线性回归设定中, transformer 的前向传播可以被理解为隐式执行梯度下降、岭回归或最小二乘估计等算法; Zhang et al.^[14] 则从训练动力学角度分析了 transformer 如何学会线性模型的上下文学习。更近期的研究也开始从更宽泛的角度理解上下文学习: Lampinen et al.^[15] 将能够利用上下文降低后续预测损失的现象都纳入广义上下文学习的范围, Riechers et al.^[16] 则从信息论角度讨论了下一词元预测为什么会自然诱导上下文学习。总体

来看，上下文学习并不是一个孤立的 prompt 技巧，而是预训练目标、数据结构和模型架构共同作用后产生的重要能力。本文后续也将沿着这一思路，把预训练模型理解为一种由下一词元预测训练得到的上下文元学习器。

2.2 元学习与元强化学习

元学习关注的是“学习如何学习”的问题，即模型通过一组相关任务的训练，获得在新任务上利用少量数据快速适应的能力。经典的 MAML (Model-Agnostic Meta Learning) 算法通过外层优化学习一组适合快速更新的初始参数，使模型在新任务上只需少量梯度步即可取得较好表现^[6]。与普通监督学习相比，元学习更强调任务之间的共享结构：如果不同任务并非彼此独立，模型就可能在训练过程中学到一种可迁移的学习策略，而不只是记住单个任务的输入输出关系。元强化学习 (meta RL) 则将这一思想推广到序列决策场景，希望智能体在许多相关环境中训练后，能够在新环境中通过少量交互迅速调整策略^[17]。代表性工作 RL² 将快速适应过程编码在循环神经网络的隐藏状态中，使内层学习发生在前向传播和历史轨迹更新中^[7]；Meta-Gradient RL 则通过外层梯度学习强化学习算法中的目标或超参数^[18]。相关综述也将元强化学习概括为一种学习快速适应策略的方法，用以缓解深度强化学习样本效率低和泛化能力有限的问题^[19]。这些思想与本文的研究视角密切相关：如果大语言模型在预训练阶段已经从大量不同语境和任务结构中学到某种“内层适应”能力，那么 RLHF 或 RLVR 后训练就可以被理解为作用于这一适应机制之上的外层优化过程，而不仅仅是对当前输出概率的局部调整。

2.3 离线到在线强化学习与策略微调

离线到在线强化学习 (offline-to-online RL) 研究的是如何利用已有的离线数据、专家轨迹或预训练策略，来降低后续在线强化学习的探索成本和样本复杂度。与从随机策略出发的传统在线强化学习不同，这一范式假设学习者在进入在线交互之前已经拥有某种“基础”：它可能来自专家示范、离线数据集，也可能来自一个已经训练好的策略模型。早期工作已经表明，离线观测或离线数据可以在一定程度上帮助智能体识别有价值的状态和行为区域，从而避免完全从零开

始探索^[20-21]。其中，Xie et al.^[22] 提出的策略微调（policy fine-tuning）框架较为直接地刻画了这一点：如果初始策略在“覆盖”或“集中能力”（concentrability）下与高质量策略足够接近，那么在线阶段只需要较少的交互样本就可以实现有效改进。后续一些工作进一步从不同角度研究了这一问题，例如在固定在线采样策略下进行非自适应微调^[23]，或在 RLHF 中通过数据集重置来利用离线数据中的高质量状态^[24]。对于大语言模型而言，这一范式尤其自然，因为这和大语言模型的两阶段训练范式相吻合，大语言模型的强化学习后训练并不是从零开始，而是在一个强大的基模型上继续优化。Foster et al.^[25] 进一步指出，在大语言模型强化学习场景下，一个好的基模型不仅提供统计意义上的“覆盖”，也可能在计算层面降低探索难度。因而，离线到在线强化学习为本文提供了一个重要基础：预训练模型确实可以作为后续铅华学习的良好起点；但本文进一步关注的是，除了“覆盖”高质量行为之外，预训练模型是否还提供了某种可被强化学习后训练利用的快速适应机制。

2.4 大语言模型的强化学习后训练

大语言模型的后训练通常发生在一个已经较强的基模型之上，其目标不再是从零学习语言能力，而是进一步调整模型的行为，使其更符合人类偏好或特定任务目标。早期代表性范式是 RLHF，即先通过人类偏好数据训练奖励模型，再使用 PPO 等强化学习算法在 KL 约束下优化大语言模型^[2]。近年来，随着数学推理和代码任务的发展，RLVR 受到更多关注。与 RLHF 依赖人类偏好或学习得到的奖励模型（reward model）不同，RLVR 使用可验证奖励，例如数学答案是否正确、代码是否通过测试等，因此能够直接对推理任务进行强化学习优化^[3-4]。在实际训练中，这类方法通常从基模型或监督微调（Supervised Fine-Tuning, SFT）模型出发，通过 PPO、GRPO、REINFORCE++ 等策略梯度方法提高正确回答的概率，同时使用 KL 正则限制模型不要偏离参考策略太远。也正因为如此，大语言模型中的强化学习和传统从随机策略开始探索的强化学习有很大不同：它强烈依赖预训练模型已经具有的知识、推理模式和采样分布。围绕这一点，Chen et al.^[5] 对 RLVR 的作用提出了非常有影响力的质疑。他们使用大 k 下的 $\text{pass}@k$ 来衡量模型的推理覆盖，发现 RLVR 模型虽然在小 k ，尤其是 $\text{pass}@1$ 上明显优于基模型，

但在 k 变大后，基模型往往可以达到相当甚至更高的 $\text{pass}@k$ 。这一现象说明，当前 RLVR 的主要作用可能不是产生全新的推理能力，而是提高基模型已经能够采样到的正确轨迹的概率；换言之，RLVR 更像是一个“锐化器” (sharpeners)，它改善采样效率，却不一定扩展模型原有的能力边界。类似观察在 DeepSeekMath 中也已经出现：强化学习可以提升多数投票 (majority voting)，但对 $\text{pass}@k$ 的提升并不明显^[3]。

不过，将 RLVR 简单概括为“只会重新加权”也可能过于保守。后续一些工作表明，强化学习的作用和任务领域、基模型的预训练“覆盖”、训练时长、强化学习数据难度以及优化机制都密切相关。对于数学和代码等预训练中较常见的领域，强化学习往往更像是在激发、放大和重组已有能力；而在逻辑、模拟、表格推理等基模型“覆盖”不足的领域，较长时间的强化学习训练、保持探索性的采样策略或更合适的任务设置，有时可以带来更明显的能力边界扩展^[26-28]。研究指出，强化学习真正带来能力提升往往需要任务处在模型的“能力边界” (edge-of-capacity) 附近：如果任务已经被预训练充分“覆盖”，强化学习主要提升采样效率；如果任务远超模型当前能力，稀疏奖励又很难提供有效学习信号；只有当任务难度略高于基模型当前能力时，强化学习才更可能推动模型组合已有思考原语 (reasoning primitive)，并产生一定的外推泛化 (extrapolation generalization)^[28]。此外，也有工作从参数空间角度分析 RLVR 的优化动态，指出 RLVR 与监督微调可能处在不同的优化机制中：RLVR 的更新并不一定表现为大范围参数改写，而可能更多发生在模型几何中的非主方向和低曲率子空间^[29]。这些结果共同说明，大语言模型后训练中的强化学习既不是纯粹的利用 (exploitation)，也不是传统意义上完全自由的探索 (exploration)。它更像是在基模型已有知识、推理模式和表示结构之上进行搜索、放大和组合。对于本文而言，这一讨论非常关键：如果强化学习的收益不仅取决于“覆盖”，还取决于模型能否在少量反馈中调整自己的推理策略，那么就有必要在 $\text{pass}@k$ 这类“覆盖”指标之外，进一步考察模型的元适应能力，即模型是否通过后训练变得更善于利用上下文和反馈完成快速适应。

第三章 预训练的元学习解释与理论分析

本章主要从元学习角度去解释预训练。我们已经看到，预训练模型在后训练之前已经具有较强的上下文适应能力，那么这种能力从何而来？我们的核心观点是：当预训练数据中包含大量具有内部一致性的任务片段时，下一词元预测不只是学习局部词元统计规律，也会迫使模型学习如何从上下文中识别当前任务，并据此预测后续输出。为了把这一观点说清楚，本章先给出一个任务结构化的预训练模型，然后说明在该模型下自回归预训练如何诱导出上下文元学习器。之后，我们讲在线性分类和线性回归两个简化设定中分析 transformer 结构是如何体现这种机制的。

3.1 任务结构化预训练与隐式元训练

LLM 的预训练通常写成下一词元预测的形式。给定序列 $z_{1:T}$ ，自回归模型的目标是最小化如下损失函数：

$$\mathcal{L}_{\text{NTP}}(\theta) = \mathbb{E}_{z_{1:T}} \left[- \sum_{t=1}^T \log p_{\theta}(z_t | z_{<t}) \right],$$

其中 θ 为模型参数， $p_{\theta}(z_t | z_{<t})$ 表示给定序列的前 $t-1$ 个词元，以 θ 为参数的模型输出词元 z_t 的概率。注意，这个目标本身并没有显式写出“任务”或“元学习”的概念。不过，在真实文本中，一个局部片段往往并不是无结构的词元序列。一段对话有共同的意图和背景，一篇文章有共同的主题和风格，一道数学题的解答也有共同的条件和推理目标。换句话说，前文并不只是提供语言统计信息，也常常提供关于当前“任务”的信息。为了刻画这一点，本文先引入一个任务结构化的预训练模型。

定义 3.1.1 (任务结构化回合) 设 $\mathcal{T}$ 为任务空间， μ 为任务分布。每个任务 $\tau \in \mathcal{T}$ 对应一个数据分布 D_{τ} ，用于生成输入输出对 $(x, y) \in \mathcal{X} \times \mathcal{Y}$ 。一个长度为 N 的

任务结构化回合由如下过程生成：

$$\tau \sim \mu, \quad S_N = \{(x_i, y_i)\}_{i=1}^N \sim D_\tau^N, \quad (x_q, y_q) \sim D_\tau,$$

其中 S_N 称为上下文样本, (x_q, y_q) 称为查询 (*query*) 样本。将该回合序列化后, 可以写成 $Z = (x_1, y_1, \dots, x_N, y_N, x_q, y_q)$ 。

这里的序列化方式只是为了让自回归模型可以处理这类数据。真正关键的是, 在预测 y_q 时, 模型已经能够看到 S_N 和 x_q 。

定义 3.1.2 (任务一致性 (task coherence)) 如果一个回合中的上下文样本 S_N 和查询样本 (x_q, y_q) 由同一个潜在任务 τ 生成, 则称该回合满足任务一致性。对应的任务结构化回合的分布记作 $\mathcal{P}_{\text{coh}}$ 。

任务一致性意味着上下文样本和查询样本并不是简单地独立拼接在一起的。它们共享同一个潜在生成机制, 因此 S_N 可以提供关于查询样本的信息。例如, 在分类任务中, S_N 和 (x_q, y_q) 共享同一条分类边界; 在回归任务中, 它们共享同一个回归参数; 在语言任务中, 上下文和后续回答共享同一个语义目标、格式约束和推理状态。因此, 在任务一致性的条件下, 模型如果想准确预测 y_q , 就不能只看 x_q , 还需要从 S_N 中推断当前任务的结构。

为了使后续理论分析更加明确, 本文进一步考虑一类具有共享潜在结构的任务族。第 3.3 节和第 3.4 节的线性分类和线性回归理论都将基于这一思想展开。

假设 3.1.1 (共享低维结构 (shared latent structure)) 每个任务 τ 可以由一个任务参数 $w_\tau \in \mathbb{R}^d$ 描述, 并且存在一个跨任务共享的低维子空间 $U \in \mathbb{R}^{d \times k} (k \ll d)$ 使得 $U^\top U = I_k$ 且 $w_\tau = U a_\tau$, 其中 $a_\tau \in \mathbb{R}^k$ 是任务 τ 的低维参数。任务分布 D_τ 通过 w_τ 决定, 例如分类边界、回归函数或条件输出分布都由 w_τ 控制。

假设 3.1.1 告诉我们, 不同任务之间并非完全无关, 而是共享某种可复用的结构。预训练阶段可以利用大量任务学习共享结构 U ; 而在面对一个新任务时, 模型只需要根据上下文样本 S_N 判断当前任务的低维参数 a_τ 。因此, 新任务上的适应难度不再主要由环境维度 d 决定, 而更多取决于内在维度 k 。

为了说明任务一致性的重要性, 我们还引入一个对照分布。

定义 3.1.3 (打乱回合分布 (shuffled episode distribution)) 给定同样的任务分布 μ 和任务条件分布族 $\{D_\tau\}_{\tau \in \mathcal{T}}$, 打乱回合分布 $\mathcal{P}_{\text{shuf}}$ 由如下过程生成:

$$\tau_1, \dots, \tau_N, \tau_q \stackrel{\text{i.i.d.}}{\sim} \mu, \quad (x_i, y_i) \sim D_{\tau_i}, \quad (x_q, y_q) \sim D_{\tau_q}.$$

也就是说, 上下文中的每个样本和查询样本分别来自独立采样的任务。这里的构造尽量保持单个样本的边际分布不变, 但破坏了 S_N 和 (x_q, y_q) 之间通过共同任务产生的联系。

这个对照分布说明了一个重要问题: 下一词元预测本身并不自动等价于元学习。在 $\mathcal{P}_{\text{shuf}}$ 下, 模型仍然可以学习到输入输出的边际统计规律; 但由于上下文样本不再携带关于查询任务的有效信息, 模型没有必要从 S_N 中推断当前任务。相反, 在 $\mathcal{P}_{\text{coh}}$ 下, 预测 y_q 需要利用回合内部的任务一致性, 因此标准的自回归训练目标会鼓励模型学习一种上下文依赖的预测规则。

从这个意义上说, 任务结构化预训练可以被看做一种隐式元训练 (meta training)。它并没有显式给出任务编号, 也没有显式要求模型执行某个学习算法; 但是, 当训练序列由大量任务一致的回合构成时, 模型为了降低下一词元预测损失 $\mathcal{L}_{\text{NTP}}$, 需要学会从上下文提取任务信息, 并把这种信息用于后续预测。下一节将进一步说明, 在总体层面上, 这一过程的最优预测器具有自然的贝叶斯元预测器 (Bayes meta-predictor) 形式。

3.2 预训练模型作为上下文元学习器

上一节给出了任务结构化预训练的基本设定。关键点在于: 在任务一致性下, 上下文样本 S_N 和查询样本 (x_q, y_q) 来自同一个潜在任务, 因此 S_N 不只是普通前缀样本, 而是包含了关于当前任务的信息。本文进一步说明, 在这一设定下, 下一词元预测的目标自然会诱导出一个上下文元学习器。为了把这个观点写清楚, 我们只关注序列中查询输出 y_q 的预测。对于自回归模型而言, 当回合被序列化为 $(x_1, y_1, \dots, x_N, y_N, x_q, y_q)$ 时, 预测 y_q 的条件分布可以写为

$$g_\theta(x_q, S_N) = p_\theta(\cdot \mid x_q, S_N).$$

因此，一个原本用于下一词元预测的语言模型，在任务结构化回合上自然诱导出一个学习器：它接收上下文样本 S_N 和查询输入 x_q ，输出对 y_q 的预测分布。本文将这个诱导出的学习器称为上下文元学习器（contextual meta-learner）。

在整体层面，考虑如下的损失函数：

$$\mathcal{L}_{\text{qry}}(p) = \mathbb{E}_{\mathcal{P}_{\text{coh}}}[-\log p(y_q | x_q, S_N)],$$

其中 $\mathcal{P}_{\text{coh}}$ 是定义 3.1.2 中任务一致回合分布。这个损失可以看做 $\mathcal{L}_{\text{NTP}}$ 中对应查询输出词元的一部分。下面的命题说明，在任务一致数据上，该损失的最优解正是贝叶斯元预测器。

命题 3.2.1 (任务一致下的总体最优解) 假设回合按照定义 3.1.1 和定义 3.1.2 生成，且模型类包含任意条件分布 $p(y_q | x_q, S_N)$ ，则 $\mathcal{L}_{\text{qry}}$ 的任意最优解满足 $p^*(y_q | x_q, S_N) = \mathbb{P}(y_q | x_q, S_N)$ 几乎处处成立，其中 $\mathbb{P}(\cdot)$ 表示真实数据分布。进一步地，由于上下文样本和查询样本共享同一个潜在任务 τ ，该条件分布可以写成

$$\mathbb{P}(y_q | x_q, S_N) = \int_{\mathcal{T}} \mathbb{P}_{\tau}(y_q | x_q) \mathbb{P}(d\tau | S_N, x_q).$$

命题 3.2.1 的证明并不复杂（见附录 A.1），本质上来自于交叉熵损失的基本性质：在所有条件分布中，最小化负对数似然的最优解就是真实条件分布。它的重要性在于解释了“预训练作为元学习”的含义。在任务一致回合中，真实条件分布 $\mathbb{P}(y_q | x_q, S_N)$ 并不是一个只依赖 x_q 的普通预测器，而是先根据 S_N 更新对潜在任务 τ 的认识，再在该任务下预测 y_q 。因此，在理想总体情况下，下一词元预测的最优预测目标本身就具有元学习形式。¹

相反，如果回合内部的任务关系被打乱，那么上下文就不再提供查询任务的信息。下面的命题说明，下一词元预测本身并不自动产生元学习能力。模型是否需要学习“从上下文中推断任务”，取决于训练序列中是否存在可利用的任务一致性。在打乱的任务下，模型仍然可以学到输入输出之间的边际规律，也可能取得较低的查询损失；但由于 S_N 和查询任务无关，最优预测器没有理由把 S_N 当

¹ 结合假设 3.1.1 中的共享低维结构，这一点可以更直观地理解。若每个任务参数满足 $w_{\tau} = U a_{\tau}$ ，那么预训练阶段可以学习跨任务共享的结构 U ，而上下文样本 S_N 可以帮助模型识别当前任务的低维参数 a_{τ} 。换句话说，最优预测器并不是为每个新任务从头学习一个 d 维参数，而是利用预训练得到的共享结构，把新任务适应转化为一个更低维的推断问题。这正是后续线性分类（回归）理论要形式化说明的现象。

作支持集使用。由此可以看出，任务一致性是将预训练解释为隐式元训练的关键条件。

命题 3.2.2 在定义 3.1.3 的打乱回合分布 $\mathcal{P}_{\text{shuf}}$ 下，假设上下文样本 S_N 与查询样本 (x_q, y_q) 独立，则 $\mathbb{P}(y_q | x_q, S_N) = \mathbb{P}(y_q | x_q)$ 几乎处处成立。因此， $\mathcal{L}_{\text{qry}}$ 的总体最优解不需要利用上下文样本 S_N 。

为了衡量上下文是否带来了适应效益，可以定义一个简单的“上下文增益”（context gain）。设 R_N^* 表示在给定 N 个上下文样本时的最优风险：

$$R_N^* = \inf_p \mathbb{E}[-\log p(y_q | x_q, S_N)].$$

定义 $R_0^* = \inf_p \mathbb{E}[-\log p(y_q | x_q)]$ 表示不使用上下文样本时的最优风险。则贝叶斯层面的“上下文增益”可以写作 $\text{CG}^*(N) = R_0^* - R_N^*$ 。

命题 3.2.3 (上下文增益与条件互信息) $\text{CG}^*(N) = I(y_q; S_N | x_q)$ 。

因此，使用上下文的收益恰好等于上下文样本 S_N 在给定 x_q 后对查询输出 y_q 提供的额外信息量。也即，如果 S_N 包含关于当前任务的信息，并且这些信息有助于预测 y_q ，那么 $I(y_q; S_N | x_q) > 0$ ，上下文学习就有真实收益；如果 S_N 与查询任务无关，例如在打乱的任务下，这个条件互信息为 0，上下文不会改善贝叶斯最优风险。也就是说，“上下文增益”并不是 prompt 技巧带来的表面现象，而是来自任务一致数据中的统计信息结构。

总而言之，在任务一致的预训练分布上，下一词元预测的总体目标包含一个天然的元学习问题。模型为了预测查询输出，需要利用上下文样本推断潜在任务；而在存在共享低维结构时，预训练可以进一步把这种适应过程变成对低维任务状态的推断，接下来的两节将分析这一机制。

3.3 线性分类中的元学习理论

上一节从总体风险的角度说明，在任务一致的预训练分布上， $\mathcal{L}_{\text{NTP}}$ 的最优预测器具有贝叶斯元预测器的形式。不过，这个结论本身还没有说明一个具体模型（例如 transformer）是否真的能够通过训练学到共享结构。本节结合 Magen et

al.^[9] 的理论结果，讨论一个简化但非常清晰的设定：任务是线性分类任务，任务之间共享一个低维子空间，模型是一个线性 transformer。我们将要去说明：在合适的任务结构下，经过训练的 transformer 可以成为一个近似最优的元学习器。

回顾一下假设 3.1.1，共享低维结构为 $U \in \mathbb{R}^{d \times k}$ ，满足 $U^\top U = I_k$ ，且 $k \ll d$ 。每个任务 τ 由一个低维任务参数 $a_\tau \in \mathbb{R}^k$ 决定，其在原始 d 维空间中的分类方向为 $w_\tau = U a_\tau$ 。

我们采用 Magen et al.^[9] 中的任务设定： a_τ 可以理解为从半径为 R 的 k 维球面上随机采样。给定任务方向 w_τ 后，样本有一个二分类高斯混合模型（Gaussian mixture model）生成：

$$y_{\tau,i} \sim \text{Unif}(\{\pm 1\}), \quad z_{\tau,i} \sim \mathcal{N}(0, I_d), \quad x_{\tau,i} = y_{\tau,i} w_\tau + z_{\tau,i}.$$

也就是说，正负两类样本分别来自均值为 w_τ 和 $-w_\tau$ 、协方差为 I_d 的高斯分布。不同任务的分类方向 w_τ 不同，但它们都位于同一个共享子空间 $\text{span}(U)$ 中。因此，预训练阶段真正可以跨任务学习的是共享结构 U ，而测试时需要根据少量上下文样本识别当前新任务的低维参数 a_τ ，或者等价地识别其高维方向 $w_\tau = U a_\tau$ 。

测试阶段给定一个新任务，模型看到 M 个上下文样本 $\{(x_i, y_i)\}_{i=1}^M$ ，以及一个未标注的查询输入 x_{M+1} ，目标是预测其标签 y_{M+1} 。这个设定正好体现了元学习任务的本质：模型不能在测试任务上更新参数，而只能利用上下文样本完成快速适应。如果模型已经通过预训练学到了共享子空间 U ，那么新任务中的主要困难就从估计一个 d 维分类方向，转化为估计一个 k 维任务参数。

下面考虑模型结构。对于一个包含 N 个上下文样本和一个查询样本的训练任务，我们将其编码为矩阵

$$E = \begin{pmatrix} x_1 & x_2 & \cdots & x_N & x_{N+1} \\ y_1 & y_2 & \cdots & y_N & 0 \end{pmatrix} \in \mathbb{R}^{(d+1) \times (N+1)},$$

其中最后一列的标签位置填入 0，表示查询样本的标签未知。我们考虑线性 transformer，即将标准注意力模块中的 softmax 替换为单位矩阵，并采用一个凸参数

化。经过这一简化后，模型对查询标签的预测可以写成

$$\hat{y}(E; W) = \left(\frac{1}{N} \sum_{i=1}^N y_i x_i \right)^\top W x_{N+1}.$$

这里 $W \in \mathbb{R}^{d \times d}$ 是训练得到的参数。由于在高斯混合模型中， $\mathbb{E}[y_i x_i | w_\tau] = w_\tau$ ，所以 $\hat{S}_N := \frac{1}{N} \sum_{i=1}^N y_i x_i$ 可以看作对当前任务方向 w_τ 的估计。矩阵 W 的作用则是通过大量训练任务学到的跨任务结构。如果训练后的 W 接近共享子空间投影 $UU^\top$ ，那么模型的预测过程就可以理解为：先从上下文中估计当前任务方向，再利用预训练学到的共享子空间进行去噪，最后对查询样本进行分类。

训练时，模型在 B 个任务上最小化查询样本的分类损失。令 E_b 表示第 b 个训练任务对应的输入矩阵，经验损失可以写成

$$L(W) = \frac{1}{B} \sum_{b=1}^B \ell(y_{b,N+1} \cdot \hat{y}(E_b; W)),$$

其中 ℓ 可以是对数损失或指数损失。由于 $\hat{y}(E; W)$ 对 W 是线性的，在训练数据可分的情况下，梯度下降具有经典的隐式偏好（implicit bias）：它不会收敛到任意解，而是在方向上收敛到 Frobenius 范数意义下的最大间隔解（max-margin solution）。具体而言，令

$$W_{\text{MM}} = \arg \min_A \|A\|_F^2, \quad \text{s.t.} \quad \left(\frac{1}{N} \sum_{i=1}^N y_{b,i} x_{b,i} \right)^\top A y_{b,N+1} x_{b,N+1} \geq 1, \quad \forall b \in [B].$$

在合适步长和可分条件下，梯度下降得到的 W_t 在方向上收敛到 W_{MM}^1 。因此，分析训练后的线性 transformer 可以转化为分析这个最大间隔解的泛化能力。这一点是该理论结果的关键：训练动态通过隐式偏好选择了一个特殊的共享结构矩阵，而不是任意能拟合训练任务的矩阵。

结合 Magen et al.^[9] 的讨论，我们给出主结论的非正式表述。完整条件包括信号强度、训练任务数、每个训练任务中的上下文样本数，以及若干用于保证集中不等式成立的技术条件；这些条件会在附录 A.2 中作进一步说明。

¹ 具体而言，梯度下降的隐式偏好现象（也称作“隐式正则化”，implicit regularization）是优化算法在高维空间中“过参数化”（overparameterization）产生的结果，我们这里不对此做过多展开，可参见^[30-31]。

定理 3.3.1 (线性 transformer 作为近似最优元学习器, 非正式表述) 考虑上述共享低维子空间中的高斯混合模型分类任务。在适当的条件下, 以至少 $1 - \delta$ 的概率, 训练得到的 W_{MM} 在一个新的测试任务上满足如下的错误率上界:

$$\mathbb{P}(\text{sign}(\hat{y}(E; W_{\text{MM}})) \neq y_{M+1}) \leq 6 \exp \left(- \frac{c(1 \wedge \sqrt{BR^2/(dk)})}{\log^2(B/\delta)} \left(\sqrt{k} \wedge \tilde{R} \wedge \sqrt{\frac{M \tilde{R}^4}{k}} \right) \right),$$

其中 R 是训练任务的信号强度, $\tilde{R}$ 是测试任务的信号强度¹, B 是训练任务数, M 是测试时的上下文样本数, $c > 0$ 为常数, $a \wedge b = \min\{a, b\}$ 。

定理 3.3.1 揭示了样本复杂度中的维度依赖。当训练任务数 B 足够大时², 式中的因子 $1 \wedge \sqrt{BR^2/(dk)}$ 可以看作常数。此时, 为了让测试错误率达到一个小常数, 只需要大约 $M = \tilde{O}(k/\tilde{R}^4)$ 个上下文样本。等价地, 训练过的模型需要 $O((k/\tilde{R}^4) \cdot \log^2(1/\epsilon) \cdot \log^4(B/\delta))$ 来以至少 $1 - \delta$ 的概率达到至多 ϵ 的分类错误率。相比之下, 如果一个学习器只看到新任务的 M 个样本, 而不知道共享子空间 U , 那么它在信息论意义上通常需要 $\Omega(d/\tilde{R}^4)$ 个样本才能达到相同量级的错误率。另一方面, 即使是一个提前知道真实子空间 U 的最优元学习器, 也需要 $\Omega(k/\tilde{R}^4)$ 个样本。因此, 训练后的线性 transformer 在这个设定下几乎达到了知道真实共享子空间的最优元学习器的样本复杂度。

定理 3.3.1 也很好地解释了预训练为什么可以带来元学习优势。单任务学习器面对新任务时, 只能在 d 维空间中从头估计分类方向 w_τ ; 而经过任务结构化预训练的 transformer 已经从大量相关任务中学到了共享子空间 U , 因此测试时只需要在 k 维有效空间中完成适应。换句话说, 预训练的作用不是直接记住某一个任务, 而是学习跨任务可复用的表示; 上下文样本的作用也不是重新训练模型参数, 而是在这个表示下识别当前任务。

-
- 1 回顾一下训练任务 τ 的低维任务参数采样与半径为 R 的 k 维球面, 也即 $a_\tau \sim \text{Unif}(R \cdot \mathbb{S}^{k-1})$; 对应的测试任务 $\tilde{\tau}$ 满足 $a_{\tilde{\tau}} \sim \text{Unif}(\tilde{R} \cdot \mathbb{S}^{k-1})$ 。从直观上看, R 控制的是两类高斯分布的分离程度, 也就是训练任务的“信噪强度”(signal-to-noise strength): R 越大, 正负类越容易区分; R 越小, 分类任务越难。
 - 2 需要的训练任务数 $B = \Omega(dk/R^2)$ 看似会和环境维度 d 直接相关, 但事实上 B 不会直接依赖 d , 而是依赖所谓“信噪比”(signal-to-noise ratio, SNR), 定义为 $\|w_\tau\|/\|z_\tau\| \simeq R/\sqrt{d}$ (因为高斯噪声 $\|z_\tau\| \simeq \sqrt{d}$)。因此需要的训练任务数为 $B = \Omega(k/\text{SNR}^2)$; 同理, 需要的训练样本数 N 也不会直接和 d 相关。

3.4 线性回归中的元学习理论

上一节通过线性分类说明，当不同任务共享低维结构时，经过训练的线性 transformer 可以利用这种结构在新任务上实现快速适应。本节考虑一个更简单的线性回归版本。在这个设定中，我们可以更直接地看到，预训练学习到的共享子空间如何在新任务上的误差从依赖环境维度 d 降低为依赖内在维度 k 。

我们仍然沿用假设 3.1.1 中的共享低维结构。给定任务 τ 后，样本由线性回归模型生成： $x_i \sim \mathcal{N}(0, I_d)$, $y_i = x_i^\top w_\tau$ 。为了突出主要机制，本节考虑无观测噪声的情形；若加入独立标签噪声，误差中会增加与噪声方差相关的项，但下面的 k 与 d 的维度对比不会改变。

给定上下文样本 $S_N = \{(x_i, y_i)\}_{i=1}^N$ ，定义上下文统计量 $\hat{w}_N = \frac{1}{N} \sum_{i=1}^N y_i x_i$ 。由于 $y_i = x_i^\top w_\tau$ 且 $x_i \sim \mathcal{N}(0, I_d)$ ，我们有 $\mathbb{E}[\hat{w}_N | w_\tau] = w_\tau$ 。因此， $\hat{w}_N$ 可以看作由上下文样本得到的当前任务的参数估计。类似上一节的线性 transformer，我们考虑预测器为：

$$\hat{y}_q(S_N, x_q; W) = \hat{w}_N^\top W x_q,$$

其中 $W \in \mathbb{R}^{d \times d}$ 是通过跨任务训练得到的参数。若 $W = UU^\top$ ，模型等价于先把 $\hat{w}_N$ 投影到共享子空间，再对查询样本预测 $\hat{y}_q = \hat{w}_N^\top U U^\top x_q$ 。这个投影的作用是去掉 $\hat{w}_N$ 中正交于 $\text{span}(U)$ 的噪声，因为真实参数 w_τ 本来就只位于这个 k 维子空间中。

下面先说明为什么均方损失（mean square error, MSE）下的隐式偏好会自然选择这个投影。我们考虑一个理想化的预训练条件：训练任务足够丰富，使得模型需要对所有 $w \in \text{span}(U)$ 和所有 $x \in \mathbb{R}^d$ 满足正确预测关系 $w^\top W x = w^\top x$ 。这个条件可以理解为总体层面或无限任务极限下的插值（interpolation）约束。它只要求模型在所有可能任务所在的共享子空间上正确工作，而不要求模型在与任务无关的方向上学习任何内容。

命题 3.4.1 (线性回归中的隐式偏好) 考虑所有满足对 $\forall w \in \text{span}(U)$, $\forall x \in \mathbb{R}^d$ 都有 $w^\top W x = w^\top x$ 的矩阵 W 。在这些插值解中，Frobenius 范数最小的唯一解为 $W^* = UU^\top$ 。因此，在该线性回归设定中，若从 $W_0 = 0$ 出发对 MSE 做梯度下降，并且训练约束可插值且等价于上述线性约束，则梯度下降收敛到的解为 W^* 。

命题 3.4.1 告诉我们，由于所有任务参数都在 $\text{span}(U)$ 中，正确预测只要求模型在这个子空间上保持单位矩阵；至于正交于 $\text{span}(U)$ 的方向，它们对任务没有帮助。MSE 下从零初始化出发的梯度下降会选择范数最小的插值解，因此会把这些无关方向设为 0，最终得到共享子空间投影 $UU^\top$ 。这正是线性回归任务中的预训练效应：跨任务训练不是学习某一个具体任务的参数，而是学习所有任务共同所在的结构。

接下来分析新任务上的误差。设测试任务参数为 $w = Ua$ ，给定 M 个上下文样本，仍然使用 $\hat{w}_M = M^{-1} \sum_{i=1}^M y_i x_i$ 。如果模型已经通过预训练学到 $W = UU^\top$ ，则带有共享结构的预测器为 $\hat{y}_q^{\text{meta}} = \hat{w}_M^\top UU^\top x_q$ 。作为对照，不使用共享结构的单任务预测器为 $y_q^{\text{single}} = \hat{w}_M^\top x_q$ 。

定理 3.4.1 (线性回归中的元学习样本复杂度优势) 考虑上述无噪声线性回归模型。给定测试任务参数 $w \in \text{span}(U)$ ，并令 $x_q \sim \mathcal{N}(0, I_d)$ ， $y_q = x_q^\top w$ 。那么

$$\mathbb{E}[(\hat{y}_q^{\text{meta}} - y_q)^2 \mid w] = \frac{k+1}{M} \|w\|_2^2, \quad \mathbb{E}[(\hat{y}_q^{\text{single}} - y_q)^2 \mid w] = \frac{d+1}{M} \|w\|_2^2.$$

因此，利用预训练学到的共享子空间可以将新任务上的适应误差从 d/M 量级降低到 k/M 量级。

这个定理展示了最直接的元学习优势。单任务估计器 $\hat{w}_M$ 虽然是 w 的无偏估计，但它的估计噪声分布在整个 d 维空间中；如果不知道共享结构，就必须承受 d 维噪声。相反，元学习器已经在预训练阶段学到 U ，因此可以把 $\hat{w}_M$ 投影回 $\text{span}(U)$ ，只保留与真实任务参数相关的 k 维部分。于是，达到给定均方误差所需的上下文样本数从与 d 成正比变为与 k 成正比。

本节的分析与上一节线性分类中的理论形成互补。线性分类部分说明，在更复杂的分类损失下，线性 transformer 也可以通过训练学到共享结构，并达到接近最优元学习器的样本复杂度；线性回归部分则用更直接的计算展示了同一机制：预训练学习共享结构，上下文提供当前任务的带噪估计，而模型利用共享结构完成去噪和预测。

第四章 强化学习后训练中的“覆盖”与“元适应”

上一章从元学习角度分析了预训练的作用。在任务结构化数据中，下一词元预测不只是学习局部词元的统计规律，也会促使模型利用上下文推断当前任务，并据此预测后续输出。特别地，在任务一致性假设（定义 3.1.2）下，上下文样本 S_N 与查询样本 (x_q, y_q) 共享同一个潜在任务，因此最优预测器自然具有贝叶斯元预测器的形式。

本章进一步讨论强化学习后训练的作用。与预训练阶段不同，RLHF 或 RLVR 在给定奖励反馈的情况下继续优化基模型。因此，大语言模型的强化学习后训练更接近一种从预训练策略出发的在线策略微调过程：模型根据输入生成回答或推理轨迹，奖励模型或验证器对该轨迹给出反馈，随后算法通过策略梯度或偏好优化（preference optimization）方法提高高奖励输出的概率。

已有研究常常从“覆盖”的角度解释这一过程。直观地说，如果预训练模型本身已经对高质量回答或正确推理轨迹分配了非零概率质量，那么强化学习后训练就可以通过奖励信号放大这些轨迹，使模型在较少采样次数下更容易给出正确答案。这一解释与离线强化学习、离线到在线强化学习、甚至是在线强化学习¹中的“覆盖”条件密切相关，也为理解 RLVR 中 $\text{pass}@1$ 提升而 $\text{pass}@k$ 在 k 很大时不一定提升的现象提供了重要视角。

本文并不否认“覆盖”解释的重要性。但从元学习视角看，“覆盖”并不是全部。上一章已经说明，预训练模型可能不只是一个静态预测器，而是一个能够利用上下文进行任务适应的元学习器。因此，本章进一步讨论：强化学习后训练是否不仅提高已有高奖励轨迹的概率，也可能进一步优化模型利用上下文和反馈进行快速适应的机制。为此，本章将先形式化大语言模型后训练与“覆盖”解释，再引入“元适应”视角，并给出“覆盖”增益与“元适应”增益的理论分解，最后通过 $\text{pass}@k$ 和上下文一致性实验进行分析。

¹ 在线强化学习中的核心概念是探索，而探索本质上就是通过主动选择动作去增加对状态-动作空间中“尚未充分访问区域”的“覆盖”，从而让学到的价值函数或策略不只在已有经验附近有效^[32]。

4.1 大语言模型后训练作为在线策略微调及“覆盖”解释

本节先给出大语言模型后训练的基本形式化。为了与上一章保持一致，我们仍然从任务结构化（定义 3.1.1）的角度出发。上一章中，一个任务结构化回合由潜在任务 τ 、上下文样本 S_N 和查询样本 (x_q, y_q) 组成；模型需要根据 S_N 和 x_q 预测 y_q 。在强化学习后训练中，模型不再只是预测一个监督标签，而是生成一个完整回答、推理链或程序，并根据奖励反馈调整策略。

定义 4.1.1 (大语言模型后训练回合) 设 $\mathcal{T}$ 为任务空间， μ 为任务分布。每个任务 $\tau \in \mathcal{T}$ 对应一个任务分布 D_τ 和一个奖励函数 r_τ 。一个大语言模型后训练回合由如下过程生成：

$$\tau \sim \mu, \quad x \sim D_\tau, \quad y \sim \pi_\theta(\cdot | x),$$

其中 x 表示输入， y 表示模型生成的回答、推理轨迹或程序， $\pi_\theta(\cdot | x)$ 是参数为 θ 的大语言模型策略， $r_\tau(x, y) \in \{0, 1\}$ 表示回答 y 在任务 τ 下获得的奖励。

在不同的后训练范式中，奖励函数的来源有所不同。在 RLHF 中，奖励通常来自由人类偏好数据训练得到的奖励模型；在 RLVR 中，奖励则来自可验证规则，例如数学答案是否正确、代码是否通过单元测试、形式化证明是否被验证器接受等。虽然这些奖励形式不同，但从策略优化角度来看，他们都可以被写成统一如下目标：

$$J(\theta) = \mathbb{E}_{\tau \sim \mu, x \sim D_\tau, y \sim \pi_\theta(\cdot | x)} [r_\tau(x, y)].$$

后训练的目标是从一个预训练得到的初始策略 π_0 出发，寻找一个新的策略 π_θ ，使得 $J(\theta)$ 尽可能大。因此后训练对应强化学习中的策略优化。

在实际大语言模型后训练中，模型通常还受到一个 KL 正则项约束，使其不要过度偏离参考策略。若以 π_0 表示预训练模型或监督微调模型，则一个常见的正则化目标可以写成

$$J_{\text{KL}}(\theta) = \mathbb{E}_{\tau \sim \mu, x \sim D_\tau, y \sim \pi_\theta(\cdot | x)} \left[r_\tau(x, y) - \beta \log \frac{\pi_\theta(y | x)}{\pi_0(y | x)} \right],$$

其中 $\beta > 0$ 控制策略偏离参考模型的程度。PPO^[33]、GRPO^[3]、REINFORCE++^[34]、DAPO^[35] 等方法虽然在具体优化形式上不同，但都可以粗略理解为在奖励信号

和 KL 约束之间进行权衡，从而提高高奖励输出的概率，同时避免模型在优先反馈下发生过大的分布漂移（distribution drift）。

这个形式化说明，大语言模型后训练与传统从零开始的强化学习^[36] 有一个重要区别：策略并不是从随机初始化开始探索，而是从已经经过大规模预训练的 π_0 出发。这个初始策略通常已经具备大量知识、语言能力和一定的推理模式。对数学和代码任务而言，基模型在强化学习之前往往已经能够以较小概率生成正确解；强化学习后训练要做的，首先就是利用奖励信号把这些正确轨迹的概率提高。因此，大语言模型后训练更接近一种策略微调或离线到在线 RL：预训练模型提供初始分布，在线奖励反馈在这个分布附近进一步调整策略。

为了形式化这一点，我们定义高奖励轨迹的“覆盖”。

定义 4.1.2 (高奖励集合与策略覆盖) 给定任务 τ 和输入 x ，定义高奖励回答集合为 $\mathcal{A}_\tau(x) = \{y : r_\tau(x, y) = 1\}$ 。对任意策略 π ，定义其在 (τ, x) 上的“覆盖”概率为

$$q_\pi(\tau, x) = \mathbb{P}_{y \sim \pi(\cdot|x)}(y \in \mathcal{A}_\tau(x)) = \mathbb{E}_{y \sim \pi(\cdot|x)}[r_\tau(x, y)].$$

如果 $q_\pi(\tau, x) > 0$ ，则说明策略 π 至少有一定概率采样到高奖励回答；如果 $q_\pi(\tau, x) = 0$ ，则说明在当前采样分布下，高奖励回答完全不可达。

在这个定义下，pass@ k 可以看作“覆盖”概率的一个采样版本。如果对同一个输入独立采样 k 个回答，那么至少有一个回答获得奖励 1 的概率

$$\text{pass}@k(\pi; \tau, x) = 1 - (1 - q_\pi(\tau, x))^k.$$

因此，较大的 pass@ k 表明模型在 k 次采样中更有可能“覆盖”到正确解。当 $k = 1$ 时，pass@1 更接近模型的单次采样成功率；当 k 很大时，pass@ k 更接近模型的潜在可能能力，也就是它是否在采样分布中保留了通向正确答案的轨迹。

这一点正是“覆盖”解释的核心。若预训练模型 π_0 已经满足 $q_{\pi_0}(\tau, x) > 0$ ，那么强化学习后训练可以通过奖励反馈提高这些高奖励回答的概率，使得 $q_{\pi_{\text{RL}}}(\tau, x) > q_{\pi_0}(\tau, x)$ 。在这种情况下，即使模型并没有发现全新的解题方式，pass@1 也会显著提高，因为原本低概率的正确轨迹被重新加权到了更高概率区域。相反，如果 $q_{\pi_0}(\tau, x)$ 极小甚至为 0，那么模型几乎无法在在线采样中获得

正奖励，强化学习更新也难以产生有效方向。这与离线强化学习和离线到在线强化学习中的“覆盖”条件非常相似：初始数据或初始策略必须“覆盖”到足够好的状态-动作区域，否则后续优化很难可靠地改进策略。

近期的“覆盖准则”(coverage principle)可以看作对这一思想在大语言模型场景中的系统化表述。它强调，预训练是否有利于后训练，不仅取决于模型在训练文本上的平均交叉熵损失，也取决于模型是否给高质量回答分配了足够的概率质量^[37]。Chen et al.^[5]对RLVR的 $\text{pass}@k$ 分析也给出了类似观察：RLVR模型通常在小 k ，尤其是 $\text{pass}@1$ 上明显优于基模型；但当 k 足够大时，基模型往往也可以采样到相当甚至更多的正确解。这说明，在许多推理任务中，RLVR的重要作用可能不是从零产生全新的推理轨迹，而是提高基模型已有高奖励轨迹的采样概率，从而改善采样效率。

不过，“覆盖”解释主要刻画的是“高奖励轨迹是否已经存在于模型分布中”以及“强化学习是否提高了这些轨迹的概率”。对于大语言模型而言，这一视角虽然重要，但还没有直接刻画模型如何利用上下文、任务结构或反馈信息进行快速适应。根据第三章的讨论，预训练模型已经具有一定的上下文元学习能力；因此，强化学习后训练作用在这样的模型之上时，优化的对象可能不仅是单个输入下的输出概率，也可能包括模型利用任务信息调整行为的方式。下一节将从这一角度出发，把强化学习后训练进一步理解为作用在预训练元学习器之上的外层优化过程。

4.2 强化学习后训练作为元学习器的外层优化

上一节将大语言模型后训练写成了从预训练策略 π_0 出发的在线策略微调过程。在这一表述中，输入 x 可以看作状态，模型生成的回答、推理链或程序 y 可以看做动作或轨迹，奖励模型或验证器给出奖励 $r_\tau(x, y)$ 。这种观点自然解释了强化学习后训练为什么能够提高高奖励轨迹的采样概率。不过，如果结合第三章的讨论，预训练模型并不只是一个静态策略。由于预训练数据中存在大量任务结构和上下文一致性，模型可能已经学到一种基于上下文的快速适应机制。因此，强化学习后训练作用在这样的模型上时，优化对象也不应只理解为单个输入下的输出概率，而应理解为对整个“上下文到策略”的映射进行外层优化。

为了刻画这一点，本节把预训练模型看成一个上下文条件策略。给定上下文样本 S_N 和查询输入 x ，模型输出回答 y 的分布写作 $\pi_\theta(y | x, S_N)$ 。这里的 S_N 可以是少样本样例、历史交互、任务说明，也可以是某种与当前查询相关的上下文信息。当 $S_N = \emptyset$ 时， $\pi_\theta(y | x, \emptyset) = \pi_\theta(y | x)$ 退化为普通的策略；当 S_N 与当前任务具有一致性时，模型可以通过 S_N 推断当前任务结构，并据此改变回答方式。

定义 4.2.1 (上下文策略与适应映射) 设 π_θ 为一个上下文条件策略。如果存在一个由模型隐式实现的映射 $\mathcal{A}_\theta : S_N \mapsto \pi_\theta(\cdot | \cdot, S_N)$ ，则称 $\mathcal{A}_\theta$ 为模型的适应映射 (*adaptive mapping*)。它表示模型如何根据上下文 S_N 生成一个适用于当前任务的策略。

定义 4.2.1 并不要求模型显式地估计任务参数，也不要求模型真的执行梯度下降之类的优化算法。对于 transformer 来说， $\mathcal{A}_\theta$ 完全可以由前向传播中的注意力模块、表示更新和解码分布隐式实现。第三中的上下文学习器正是这种适应映射的一种监督学习版本：模型根据上下文样本推断当前任务，并预测查询输出。在强化学习后训练中，区别只在于模型的输出不再通过监督标签评价，而是通过奖励函数评价。

给定任务一致的后训练回合，强化学习目标可以写成

$$J(\theta) = \mathbb{E}_{\tau \sim \mu, S_N \sim D_\tau^N, x \sim D_\tau, y \sim \pi_\theta(\cdot | x, S_N)} [r_\tau(x, y)].$$

这个目标的外层期望跨越不同任务 τ ，而模型在每个任务内部都需要利用 S_N 调整自己的行为。因此，从元学习角度看，强化学习后训练并不只是优化某一个固定任务上的策略，而是在优化一个跨任务共享的适应规则 $\mathcal{A}_\theta$ 。这能够使得模型在遇到一个由上下文刻画的任务时，更快地产生高奖励行为。

为了说明上下文适应在强化学习目标中的作用，我们引入一个与定义 3.1.2 类似的任务一致性假设。

假设 4.2.1 (奖励任务一致性) 每个任务 $\tau \in \mathcal{T}$ 对应一个任务分布 D_τ 和奖励函数 r_τ 。在任务一致回合中，上下文样本 S_N 、查询输入 x 和奖励函数 r_τ 共享同一个潜在任务 τ 。此外，存在某些任务 τ, τ' 和输入 x ，使得同一个回答 y 在不同任务下的奖励不同，也即 $r_\tau(x, y) \neq r_{\tau'}(x, y)$ 。

假设 4.2.1 告诉我们，当前任务信息会影响什么样的回答是高奖励的。如果奖励与任务无关，那么上下文本身就没有必要参与策略选择；相反，如果不同任务偏好的回答不同，那么模型只有根据上下文识别当前任务，才可能稳定地产生高奖励输出。

在总体层面上，最优上下文策略具有一个自然的形式。

命题 4.2.1 (强化学习目标下的最优上下文策略) 考虑满足假设 4.2.1 的任务一致回合，并假设策略类包含任意条件分布 $\pi(y | x, S_N)$ 。对于固定的 (x, S_N) ，最大化期望奖励的总体最优策略可以取为

$$\pi^*(\cdot | x, S_N) \in \arg \max_{\pi(\cdot | x, S_N)} \mathbb{E}_{\tau | x, S_N} \left[\mathbb{E}_{y \sim \pi(\cdot | x, S_N)} [r_\tau(x, y)] \right].$$

等价地，若允许确定性策略，则最优回答满足 $y^*(x, S_N) \in \arg \max_y \mathbb{E}_{\tau | x, S_N} [r_\tau(x, y)]$ 。

命题 4.2.1 和命题 3.2.1 非常类似。命题 3.2.1 说明，在任务一致数据上，最优预测器会根据 S_N 更新对潜在任务的认知，再预测 y_q 。这里的区别在于，目标函数从负对数似然变成了奖励最大化。因此，最优策略不再预测真实标签分布，而是选择在当前任务后验下期望奖励最高的回答。只要 S_N 包含关于任务 τ 的信息，并且奖励函数确实依赖于 τ ，那么利用上下文就有可能提高期望奖励。

这说明强化学习后训练可以被理解为一种外层元优化（outer-loop meta optimization）。预训练阶段已经形成了一个初始适应映射 $\mathcal{A}_{\theta_0}$ ，它使模型能够根据上下文进行一定程度的任务识别和行为调整；强化学习后训练则在奖励反馈下继续调整参数，从而得到新的适应映射 $\mathcal{A}_{\theta_{RL}}$ 。如果强化学习只是提高某些已有高奖励轨迹的概率，那么它主要体现为“覆盖”或采样效率的提升；但如果强化学习改变了模型利用 S_N 的方式，使其在任务一致上下文中更有效地选择高奖励行为，那么它就带来了“元适应”能力的提升。

需要强调的是，这一观点并不与“覆盖”解释矛盾。“覆盖”是强化学习后训练能够发生的前提，因为如果预训练策略几乎从不采样到任何高奖励轨迹，稀疏奖励就难以提供有效更新。“元适应”则进一步关心，当模型已经具有一定“覆盖”之后，强化学习是否改善了它根据上下文选择和放大合适轨迹的能力。下一节将把这两个因素区分开来，定义“覆盖”增益与“元适应”增益，并给出一个简单的理论分解。

4.3 “覆盖”增益与“元适应”增益的理论分解

上一节将强化学习后训练理解为作用在上下文条件策略 $\pi_\theta(y \mid x, S_N)$ 上的外层优化。与普通策略优化不同，这里的策略不只是根据查询输入 x 生成回答，也可以根据上下文 S_N 改变自己的行为。因此，若要分析强化学习后训练的收益来源，就需要区分两类因素：第一，模型是否已经在输出分布中“覆盖”了高奖励回答；第二，模型是否能够利用任务一致的上下文，把概率质量进一步转移到当前任务需要的高奖励回答上。

第三章已经引入了任务一致回合（定义 3.1.2）和打乱回合分布（定义 3.1.3）。这里沿用同样的思想。在任务一致评价分布中，上下文 S_N 和查询输入 x 来自同一个潜在任务 τ ，因此 S_N 可能提供关于当前任务的有效信息；在打乱评价分布中，上下文仍然保留类似的格式和条件，但不再携带当前任务的信息。因此，打乱上下文可以作为一个控制条件，它保留了少样本样例或长上下文带来的表面因素，但移除了真正的任务一致性。

沿用第 4.1 节的 $\text{pass}@k$ 定义。对于上下文策略 π ，若在给定 (τ, x, S_N) 后独立采样 k 个回答，则至少有一个回答获得奖励 1 的概率为 $\text{pass}@k(\pi; \tau, x, S_N)$ 。

定义 4.3.1 (策略的总体价值) 对任意上下文策略 π ，定义其在任务一致评价分布下的总体价值 (*value*) 为

$$V_k^{\text{coh}}(\pi) = \mathbb{E}_{\text{coh}}[\text{pass}@k(\pi; \tau, x, S_N)],$$

类似地，定义其在打乱上下文评价分布下的总体价值为

$$V_k^{\text{shuf}}(\pi) = \mathbb{E}_{\text{shuf}}[\text{pass}@k(\pi; \tau, x, S_N)].$$

定义 4.3.1 给了我们两种刻画价值的方式， V_k^{shuf} 更接近“覆盖”的刻画，因为在打乱上下文中， S_N 不再提供当前任务的信息；而 V_k^{coh} 允许模型利用任务一致上下文，因此同时包含“覆盖”和上下文“元适应”两部分因素。

定义 4.3.2 (“元适应”分数) 定义策略 π 的“元适应” (*meta-adaptation*) 分数为 $M_k(\pi) = V_k^{\text{coh}}(\pi) - V_k^{\text{shuf}}(\pi)$ 。

这个量可以看做第三章“上下文增益”（命题 3.2.3）在强化学习场景下的对应物。“上下文增益”衡量上下文在预测损失上的收益；这里的 M_k 衡量任务一致上下文相对于打乱上下文在可验证奖励或 $\text{pass}@k$ 上带来的收益。如果 $M_k > 0$ ，说明模型不只是依靠无条件“覆盖”来获得正确答案，而是在一定程度上利用了当前任务的上下文信息。

设 π_0 为预训练或监督微调得到的初始策略， π_{RL} 为经过强化学习后训练得到的策略。我们关心的是强化学习后训练在任务一致评价分布下带来的总提升，即 $V_k^{\text{coh}}(\pi_{\text{RL}}) - V_k^{\text{coh}}(\pi_0)$ 。定义 4.3.1 和定义 4.3.2 使我们可以将这一总提升拆分成两个不同来源：一部分是在打乱上下文下仍然存在的提升，对应“覆盖”或采样效率；另一部分是任务一致上下文相对于打乱上下文带来的额外提升，对应“元适应”能力的变化。我们将在定理 4.3.1 中将这一分解形式化。

为了进一步说明“元适应”增益并不是人为定义出来的剩余项，我们还考虑一种 KL 正则化的总体策略提升。定义任务一致上下文下的后验期望奖励为 $m_{\text{coh}}(x, S_N, y) = \mathbb{E}_{\text{coh}}[r_\tau(x, y) \mid x, S_N]$ ，打乱上下文下的后验期望奖励为 $m_{\text{shuf}}(x, S_N, y) = \mathbb{E}_{\text{shuf}}[r_\tau(x, y) \mid x, S_N]$ 。如果打乱上下文确实不携带当前任务信息，那么 m_{shuf} 不会真正依赖 S_N 中的任务内容。

在 KL 正则化下，我们的目标是做策略提升。对每个固定的 (x, S_N) ，令

$$\pi_\eta(\cdot \mid x, S_N) = \arg \max_{v \in \Delta(\mathcal{Y})} \left\{ \mathbb{E}_{y \sim v}[m_{\text{coh}}(x, S_N, y)] - \frac{1}{\eta} \text{KL}(v \parallel \pi_0(\cdot \mid x, S_N)) \right\}.$$

这对应 PPO 或 GRPO 等算法的优化目标（见第 4.1 节）。事实上，上述优化问题有如下闭式解（为方便起见，我们考虑回答空间 $\mathcal{Y}$ 是有限的）：

$$\pi_\eta(y \mid x, S_N) = \frac{\pi_0(y \mid x, S_N) \exp(\eta m_{\text{coh}}(x, S_N, y))}{\sum_{y'} \pi_0(y' \mid x, S_N) \exp(\eta m_{\text{coh}}(x, S_N, y'))}.$$

当 $\eta = 0$ 时，可以将 π_η 理解为 π_0 的连续延拓；当 η 增大时，策略会逐渐把更多概率质量分配给在任务一致上下文下具有更高后验奖励的回答。这是一种乘法权重更新（multiplicative weight update），是线性奖励目标加 KL 正则项后的最优指数倾斜，和镜像下降（mirror descent）有高度联系^[38-39]。因此我们在这里可以将 π_η 作为强化学习后训练得到的策略。

定理 4.3.1 (“覆盖” 增益与 “元适应” 增益的分解及非平凡性) 假设回答空间 $\mathcal{Y}$ 有限, 奖励满足 $r_\tau(x, y) \in \{0, 1\}$, 且初始策略满足 $\pi_0(y | x, S_N) > 0$ 对所有 $y \in \mathcal{Y}$ 成立。则:

1. 对任意强化学习后训练策略 π_{RL} , 有:

$$V_k^{\text{coh}}(\pi_{\text{RL}}) - V_k^{\text{coh}}(\pi_0) = \underbrace{(V_k^{\text{shuf}}(\pi_{\text{RL}}) - V_k^{\text{shuf}}(\pi_0))}_{\text{“覆盖” 增益}} + \underbrace{(M_k(\pi_{\text{RL}}) - M_k(\pi_0))}_{\text{“元适应” 增益}}.$$

2. 考虑上述 KL 正则化更新 π_η 。即 $q_0^c(\tau, x, S_N) = \mathbb{E}_{y \sim \pi_0(\cdot | x, S_N)}[r_\tau(x, y)]$, 其中 $c \in \{\text{coh}, \text{shuf}\}$ 。于是我们有

$$\begin{aligned} \left. \frac{d}{d\eta} M_k(\pi_\eta) \right|_{\eta=0} &= k \mathbb{E}_{\text{coh}} \left[(1 - q_0^{\text{coh}})^{k-1} \text{Cov}_{\pi_0}[r_\tau(x, \cdot), m_{\text{coh}}(x, S_N, \cdot) | x, S_N] \right] \\ &\quad - k \mathbb{E}_{\text{shuf}} \left[(1 - q_0^{\text{shuf}})^{k-1} \text{Cov}_{\pi_0}[r_\tau(x, \cdot), m_{\text{coh}}(x, S_N, \cdot) | x, S_N] \right]. \end{aligned}$$

特别地, 当 $k = 1$ 时, 上式化简为

$$\left. \frac{d}{d\eta} M_1(\pi_\eta) \right|_{\eta=0} = \mathbb{E}_{\text{coh}} [\text{Var}_{\pi_0}[m_{\text{coh}} | x, S_N]] - \mathbb{E}_{\text{shuf}} [\text{Cov}_{\pi_0}[m_{\text{shuf}}, m_{\text{coh}} | x, S_N]].$$

因此, 若上述一阶导数严格大于 0, 则存在 $\eta_0 > 0$, 使得对所有 $0 < \eta < \eta_0$, 都有 $M_k(\pi_\eta) > M_k(\pi_0)$ 。

定理 4.3.1 第一部分将强化学习后训练的总收益精确分解成 “覆盖” 增益和 “元适应” 增益两项; 而第二部分则进一步说明, 在 KL 正则化的强化学习更新下, “元适应” 增益可以真实地产生。直观上看, m_{coh} 表示给定任务一致上下文后的后验奖励。如果不同回答在该后验奖励下差异明显, 那么强化学习更新会把概率质量向这些上下文相关的高奖励回答移动。若这种移动不能由打乱上下文同等解释, 那么 M_k 就会增加。

为了更直观地说明 “元适应” 增益可以非平凡, 下面给出一个最简单的二任务例子。在这个例子下, 强化学习更新完全不提高打乱上下文的 “覆盖”, 但会严格提高任务一致上下文的表现。

二任务二动作模型。 令潜在任务 $\tau \in \{-1, +1\}$ 均匀分布，回答空间为 $\mathcal{Y} = \{-1, +1\}$ ，奖励为 $r_\tau(y) = \mathbf{1}\{y = \tau\}$ 。上下文只包含一个信号 $z \in \{-1, +1\}$ ，满足：

- 在任务一致分布下， z 是 τ 的带噪观察，也即 $\mathbb{P}(z = \tau) = p$ ，其中 $p > 1/2$ ；
- 在打乱分布下， z 与 τ 独立。

设初始策略为均匀策略 $\pi_0(y | z) = 1/2$ 。先计算定理 4.3.1 中的两个后验奖励函数。在任务一致分布下，给定 z 后，任务 τ 更可能等于 z 。因此

$$m_{\text{coh}}(z, y) = p \cdot \mathbf{1}\{y = z\} + (1 - p) \cdot \mathbf{1}\{y \neq z\},$$

而在打乱分布下， z 与 τ 独立，因此 $m_{\text{shuf}}(z, y) = 1/2$ 。这样一来，我们可以计算定理 4.3.1 中的方差与协方差项。由于 $\pi_0(y | z) = 1/2$ ，有 $\mathbb{E}_{\pi_0}[m_{\text{coh}}(z, \cdot) | z] = p/2 + (1 - p)/2 = 1/2$ 。于是

$$\text{Var}_{\pi_0}[m_{\text{coh}} | z] = \frac{1}{2} \left(p - \frac{1}{2}\right)^2 + \frac{1}{2} \left(1 - p - \frac{1}{2}\right)^2 = \left(p - \frac{1}{2}\right)^2 > 0.$$

另一方面，因为 $m_{\text{shuf}}(z, y) = 1/2$ 对所有 y 都成立，所以 $\text{Cov}_{\pi_0}[m_{\text{shuf}}, m_{\text{coh}} | z] = 0$ 。此外，在初始策略下，无论是在任务一致分布还是打乱分布中，单次成功概率都是 $q_0^{\text{coh}} = q_0^{\text{shuf}} = 1/2$ 。因此，代入定理 4.3.1 的一般 k 情形可得

$$\left. \frac{d}{d\eta} M_k(\pi_\eta) \right|_{\eta=0} = k \left(\frac{1}{2}\right)^{k-1} \left(p - \frac{1}{2}\right)^2 > 0.$$

这说明，KL 正则化的强化学习更新在一阶意义上会严格提高“元适应”分数。

我们也可以直接看这个更新的形式。由 KL 正则化策略提升的闭式解可知

$$\pi_\eta(y = z | z) = \frac{\exp(\eta p)}{\exp(\eta p) + \exp(\eta(1 - p))}.$$

因为 $p > 1/2$ ，所以对于任意 $\eta > 0$ ，都有 $\pi_\eta(y = z | z) > 1/2$ 。换句话说，强化学习更新会让策略更倾向于相信上下文信号 z 。在任务一致分布下，这会提高成功概率：

$$V_1^{\text{coh}}(\pi_\eta) = (1 - p) + (2p - 1)\pi_\eta(y = z | z) > \frac{1}{2} = V_1^{\text{coh}}(\pi_0).$$

另一方面，在打乱分布下， z 与 τ 独立，因此无论策略如何依赖 z ，都有 $V_1^{\text{shuf}}(\pi_\eta) = 1/2 = V_1^{\text{coh}}(\pi_0)$ 。所以在这个例子中，打乱上下文下的“覆盖”增益为 0，而“元适应”分数严格增加，也即 $M_1(\pi_\eta) - M_1(\pi_0) > 0$ 。

这个例子说明，强化学习后训练即使没有扩大静态“覆盖”，也可能通过增强模型对任务相关上下文的利用来提高表现。简而概之，“覆盖”揭示了模型是否已经能够采样到正确轨迹，而“元适应”进一步刻画模型是否能够根据当前任务信息把这些轨迹调动出来。

4.4 实验设计与结果分析

前几节从理论上将强化学习后训练的收益分解为“覆盖”增益和“元适应”增益。本节进一步通过小规模实验检验这一观点。实验的基本思路是：一方面，沿用已有工作的 $\text{pass}@k$ 分析^[5]，观察 RL 后训练是否主要提高小采样预算下的成功率；另一方面，在数学题 `prompt` 中显式构造任务一致上下文和打乱上下文，并用二者的差值衡量模型利用上下文快速适应的能力（见定义 4.3.2）¹。

模型与数据集。 实验采用一组同源模型对，以尽量减少模型结构、分词器（tokenizer）、预训练语料以及数学监督数据差异带来的混杂因素。具体而言，基模型选用 Qwen2.5-Math-7B，RL 模型选用 Qwen2.5-Math-7B-Oat-Zero。二者均为 7B 规模模型，实验中使用相同的 `prompt` 格式、相同的采样参数和相同的自动判分流程。推理框架使用 vLLM，并在两张 GPU 上进行并行推理。本文只进行评估，不重新训练模型。

数据集方面，实验使用 MATH500 作为查询集（query set）。MATH500 的每道题包含题面、标准答案、标准解答、题目类别以及难度等级。这里的类别包括 Precalculus、Prealgebra、Intermediate Algebra、Geometry 等。由于本文需要构造任务一致上下文，MATH500 比 AIME 更适合作为主实验数据集²。

为了避免从测试集中抽取示例造成数据泄露，少样本样例（few-shot exam-

1 与 Chen et al.^[5] 相比，本文的实验规模更小，目的也有所不同。Chen et al.^[5] 主要关心 RLVR 是否扩展了模型的思考边界，因此使用 $\text{pass}@k$ （大 k ）比较基模型和 RL 模型在数学、代码等任务之上的“覆盖”能力。本文不试图全面复现其大规模结果，而是在其“覆盖”分析思路之上，加入“元适应”指标 M_k ，从而考察强化学习后训练是否也会改变模型利用任务一致上下文的能力。

2 AIME 虽然常用于数学推理评测，但题目数量较少，且没有稳定的题型或类型标签；相比之下，MATH500 题目带有类别（subject）和难度（level）信息，可以较自然地构造以任务为导向的一致 / 打乱上下文。

ples) 均从 MATH 训练集中抽取。当前实验规模为 100 道 MATH500 查询样例 (query), 每个查询样例在每种 prompt 条件下采样 $m = 16$ 个完整回答 (completion), 并报告 $k \in \{1, 2, 4, 8, 16\}$ 下的 $\text{pass}@k$ 。

Prompt 条件与任务一致上下文构造。 实验包含三类 prompt 条件:

- 第一类是**零样本 (zero-shot / pilot) 条件**。该条件不加入少样本样例, 只使用原始 MATH500 问题和固定解题提示。它主要用于复现标准的“覆盖”现象, 即比较基模型和 RL 模型在不同 k 下的 $\text{pass}@k$ 曲线。
- 第二类是**任务一致 (coherent) 条件**。在该条件下, 每个查询样例前面加入若干与查询样例具有任务一致的样例。为尽可能地保证任务一致性, 对每个 MATH500 查询样例, 从 MATH 训练集中选择与该样本样例属于同一类别、难度差不超过 1、题面长度相近的样例。
- 第三类是**打乱 (shuffled) 条件**。该条件保留少样本样例的形式和长度, 但破坏任务一致性。具体而言, 对每个查询样例, 从 MATH 训练集中选择与查询样例属于不同类别、但难度差不超过 1 且题面长度相近的样例。¹

实验所用任务一致 / 打乱条件下的 prompt 基本格式如下。系统先给出若干数学题及最终答案, 提示模型将这些样例仅作为数学主题和格式的上下文信息, 然后要求模型解答最终问题。随后, 原始的评估流程中会自动追加 “Please reason step by step, and put your final answer within `\boxed{\}`.” 这一固定指令。

下面是原始 MATH500 查询样例 (第一类条件) 示例: 类别为 Precalculus。

```
Subject: Precalculus
Level: 2
Problem:
Convert the point  $(0, 3)$  in rectangular coordinates to
↪ polar coordinates.
Enter your answer in the form  $(r, \theta)$ , where  $r > 0$  and
 $0 \leq \theta < 2\pi$ .
```

¹ 需要说明的是, 实验最初尝试将完整 MATH 解答放入少样本样例, 但该版本在基模型上产生了大量异常输出, 例如复读 prompt、输出极短无效回答, 甚至出现与当前数学问题无关的文本。这个现象说明, 含完整解答的 prompt 可能引入过多格式负担, 使实验测到 prompt 鲁棒性而非上下文适应能力。因此, 最终实验改用只含答案的样例, 也即每个样例只包含题面与最终答案 (见示例), 这样可以减少长上下文对模型产生的干扰。

Answer:
 $\left(3, \frac{\pi}{2}\right)$

下面是任务一致条件（第二类条件）下的 **prompt** 示例：两个样例均来自 **Precalculus**，难度分别为 2 和 3，且题面长度与查询样例接近。

Example 1:
Problem:
Given $\mathbf{a}=(-7,0,1)^T$ and $\mathbf{b}=(4,2,-1)^T$,
find $\mathbf{a}-3\mathbf{b}$.
Final Answer:
 $\boxed{(-19,-6,4)^T}$

Example 2:
Problem:
There are infinitely many positive integers k which satisfy
 $\cos^2(k^2+6^2)^\circ=1$. Enter the two smallest solutions.
Final Answer:
 $\boxed{18}$

Now solve the following problem.
Problem:
Convert the point $(0,3)$ in rectangular coordinates to
↪ polar coordinates...

下面是打乱条件（第三类条件）下的 **prompt** 示例：这两个样例分别来自 **Prealgebra** 和 **Intermediate algebra**，难度与长度与查询样例接近，但类别不同。

Example 1:
Problem:
Given the digits 2, 4 and 7, how many different positive
↪ two-digit integers
can be formed if a digit may not be repeated?
Final Answer:
 $\boxed{6}$

Example 2:

Problem:

What is the value of $(2/3)(3/4)(4/5)(5/6)$?

Express your answer as a common fraction.

Final Answer:

$\boxed{\frac{1}{3}}$

Now solve the following problem.

Problem:

Convert the point $(0, 3)$ in rectangular coordinates to

↪ polar coordinates...

评价指标。 我们首先使用标准 $\text{pass}@k$ 衡量模型在给定采样预算下至少答对一次的概率。对每个查询样例和 prompt 条件，模型生成 $m = 16$ 个完整回答。设其中正确的完整回答数为 c_i ，则第 i 道题的 $\text{pass}@k$ 估计量为

$$\widehat{\text{pass}@k}_i = 1 - \frac{\binom{m-c_i}{k}}{\binom{m}{k}}, \quad k \leq m.$$

若 $m - c_i < k$ ，则分子视为 0，即该题在 k 次采样内至少一次答对的估计值为 1。最后对所有查询样例求平均，得到模型在某个 prompt 条件下的总体 $\text{pass}@k$ 。

对于零样本条件下的查询样例， $\text{pass}@k$ 直接作为评估指标；对于任务一致和打乱条件而言，我们进一步计算第 4.3 中定义的 V_k^{coh} 和 V_k^{shuf} 对应的样本均值版本 $\hat{V}_k^{\text{coh}}$ 和 $\hat{V}_k^{\text{shuf}}$ 。然后定义经验“元适应”分数为 $\hat{M}_k = \hat{V}_k^{\text{coh}} - \hat{V}_k^{\text{shuf}}$ 。若 $\hat{M}_k > 0$ ，说明同一个模型在任务一致上下文下比打乱上下文下表现更好，即模型能够在一定程度上利用任务一致上下文，具有“元适应”能力。进一步地，强化学习后训练带来的元适应增益定义为 $\Delta \hat{M}_k = \hat{M}_k(\pi_{\text{RL}}) - \hat{M}_k(\pi_0)$ 。

实验结果。 表 4-1 汇总了三类 prompt 条件下的 $\text{pass}@k$ 结果。这里的三类 prompt 条件分别对应标准“覆盖”分析中的零样本条件，以及用于计算元适应分数的任务一致条件和打乱条件。表 4-2 则给出了由任务一致条件和打乱条件两

组结果相减得到的“元适应”增益分数，直接对应第 4.3 节中的 M_k ：数值越大，说明模型在任务一致上下文下相当于打乱上下文获得的额外收益越明显。

表 4-1 基模型 (base) 和 RL 模型 (oat) 在零样本条件 (pilot)、任务一致条件 (coh) 和打乱条件 (shuf) 下的 $\text{pass}@k$ 结果，每一行代表一个模型在一个条件下的结果（例如 pilot_oat 表示零样本条件下的 RL 模型），每一列代表一个指标。其中 Samples 代表查询样例数，Scores 为总回答生成数（即查询样例数和每题采样数的乘积），Timeout/Empty 为超时样本数/未能解析出有效答案的输出数。 $\text{pass}@k$ 的单位是百分比。

Model	Samples	Scores	Timeout/Empty	pass@1	pass@2	pass@4	pass@8	pass@16
pilot_base	100	1600	0/12	60.6	76.0	85.8	91.3	94.0
pilot_oat	100	1600	0/1	82.1	85.9	88.4	90.4	92.0
coh_base	100	1600	0/19	54.0	69.5	80.2	87.0	91.0
coh_oat	100	1600	0/1	78.2	83.3	86.5	89.0	90.6
shuf_base	100	1600	0/22	51.8	67.4	78.2	85.2	89.3
shuf_oat	100	1600	0/1	74.8	80.5	84.0	87.1	88.8

表 4-2 有任务一致条件与打乱条件的差值得到的“元适应”增益分数与 RL 增益。第一行 $\widehat{M}_k(\pi_0)$ 表示基模型的“元适应”分数；第二行 $\widehat{M}_k(\pi_{\text{RL}})$ 表示 RL 模型的“元适应”分数；第三行 $\Delta \widehat{M}_k = \widehat{M}_k(\pi_{\text{RL}}) - \widehat{M}_k(\pi_0)$ 表示 RL 后训练带来的额外元适应增益。单位为百分比。

指标	$k = 1$	$k = 2$	$k = 4$	$k = 8$	$k = 16$
$\widehat{M}_k(\pi_0)$	2.2	2.1	2.0	1.8	1.7
$\widehat{M}_k(\pi_{\text{RL}})$	3.4	2.8	2.5	1.9	1.8
$\Delta \widehat{M}_k$	1.2	0.7	0.5	0.1	0.1

图 4-1 对表 4-2 的结果进行了可视化。左图展示了基模型和 RL 模型的“元适应”增益分数，以及 RL 模型相对于基模型的增量；右图展示这些量随采样次数增加的相对衰减趋势。该图是本文实验中对“元适应”增益部分的主要结果。作为补充，我们在图 4-2 中也展示了零样本条件下的 $\text{pass}@k$ 曲线，用于与已有“覆盖”分析对齐。

结果分析与讨论。 结合表 4-1、表 4-2 以及图 4-1、图 4-2，可以从以下几个方面来理解实验结果：

- “覆盖”现象明显。在零样本条件下，RL 模型在 k 较小时明显优于基模型，特别是 $\text{pass}@1$ 从基模型的 60.6 提升到 RL 模型的 82.1，说明强化学习后训练显著提高了模型单次采样命中正确答案的概率。与此同时，随着 k 增大，基模型的 $\text{pass}@k$ 快速上升，并在 $\text{pass}@16$ 时达到 94.0，高于 RL 模型的 92.0。这个趋势说明，基模型并非缺少正确轨迹，而是很多正确轨迹在




图 4-1 “元适应”增益分数 $\widehat{M}_k$ 及其相对变化趋势。左图中，蓝色柱表示基模型的 $\widehat{M}_k(\pi_0)$ ，橙色柱表示 RL 模型的 $\widehat{M}_k(\pi_{RL})$ ，黑色虚线表示二者差值 $\Delta \widehat{M}_k$ 。右图展示各曲线相对于 $k = 1$ 时的比率，用于观察“元适应”信号随采样次数增大而变化的趋势。

单次采样时概率较低；强化学习后训练更像是把这些已有高奖励轨迹推到更高概率区域，从而改善小 k 下的采样效率^[5]。这与我们在第 4.1 节中提到的“覆盖”解释相一致。¹

- **任务一致上下文相比打乱上下文带来“稳定但不大”的增益。**表 4-2 中，基模型和 RL 模型的 $\widehat{M}_k$ 都为正，说明任务一致样例相对于打乱样例确实提供了一定的额外帮助。具体来说，基模型的 $\widehat{M}_1$ 为 2.2，RL 模型的 $\widehat{M}_1$ 为 3.4；在 $k = 2, 4, 8, 16$ 时，两个模型的 $\widehat{M}_k$ 也都保持为正。这个结果说明，模型并不是完全忽略少样本样例中的任务信息。即便当前任务一致上下文只基于较粗的 MATH 类别标签构造，同类别、难度相近、长度相近的样例仍然能给最终查询样例带来可测量的帮助。也就是说， $\Delta \widehat{M}_k$ 确实一定程度上捕捉到了第 4.3 节中定义的“元适应”分数（定义 4.3.2）。
- **RL 模型的“元适应”增益略高于基模型。**更关键的是，RL 模型的 $\widehat{M}_k$ 在所有 k 上都高于基模型，对应的 $\Delta \widehat{M}_k$ 为正。尤其在 k 较小时，这一差异更加明显： $\Delta \widehat{M}_1 = 1.2$ ， $\Delta \widehat{M}_2 = 0.7$ ， $\Delta \widehat{M}_4 = 0.5$ 。这与第 4.3 节的理论分解相呼应：强化学习后训练的总收益不仅可以包含打乱上下文仍然存在的“覆盖”增益，也可以包含任务一致上下文带来的额外“元适应”增益。在

¹ 事实上，图 4-1 右图中的衰减趋势也可以从“覆盖”角度理解。我们从 $\widehat{M}_k$ 和 $\Delta \widehat{M}_k$ 相对于 $k = 1$ 的比率可以看到，随着采样次数的增大，“元适应”分数整体呈下降趋势。这并不矛盾，因为 $\text{pass}@k$ 衡量的是“至少一次答对”的概率。当 k 较小时，模型是否能把概率质量集中到当前任务相关的高奖励轨迹上非常重要，因此任务一致上下文的帮助更容易体现出来；当 k 较大时，普通“覆盖”本身已经能够采样出更多正确轨迹，任务一致上下文对“至少一次答对”的边际贡献自然会变小。换句话说， $\widehat{M}_k$ 的衰减并不是反驳“元适应”，而是说明“元适应”更主要影响小采样预算下的概率分配。




图 4-2 零样本条件下的基模型与 RL 模型的 $\text{pass}@k$ 曲线。蓝色曲线表示基模型，橙色曲线表示 RL 模型；灰色区域标出了 RL 模型优于基模型的部分，黑色虚线表示两模型 $\text{pass}@k$ 的差距，即 RL 模型的 $\text{pass}@k$ 减去基模型的 $\text{pass}@k$ 。该图用于观察 RL 后训练在不同采样预算下的“覆盖”或采样效率变化。

本实验中，RL 模型不只是 $\text{pass}@1$ 更高，它在任务一致上下文相对于打乱上下文的差值上也略高于基模型。这说明强化学习后训练可能在一定程度上改变了模型利用上下文信息选择答案的方式。

- **少样本样例本身可能带来了额外负担。**表 4-1 中的任务一致和打乱条件下的绝对分数都低于零样本条件下的分数。这一点并不意外，我们的解读是：任务一致和打乱条件下的 prompt 在原题前加入了样例，增加了上下文长度和格式复杂度，因此可能会带来一些副作用。¹

但是需要注意的是，当前实验仍是小规模验证。首先，评测只使用了 100 道 MATH500 查询样例和一组 7B 模型对；其次，任务一致上下文只是基于 MATH 类别标签构造，而同一类别内部仍可能包含不同题型（例如 Precalculus 内部可能同时包含向量运算、三角方程和极坐标转换），于是当前任务一致上下文只是较弱的一致性设定。因此，我们不将结果解释为强化学习创造了全新推理能力，而是将其作为与本章理论分解（定理 4.3.1）相一致的初步证据。后续更理想的做法是扩大到完整的 MATH500，并使用如基于检索（retrieval-based）或模式匹配（pattern matching）的方式来构造更接近“同一潜在任务”的上下文。

¹ 正如前面所提到的，最初使用完整解答作为样例时，基模型会出现复读 prompt、生成极短无效输出等问题，因此最终改成了只有题目和答案的样例。所以这里真正重要的不是少样本条件（也即任务一致和打乱条件）是否超过零样本条件，而是在同样加入上下文样例、同样承受 prompt 负担的情况下，任务一致的样例是否比打乱的样例更有效。也正因为如此， $M_k = V_k^{\text{coh}} - V_k^{\text{shuf}}$ 比单独看任务一致条件下的绝对分数更适合作为“元适应”指标。

总体而言，这组实验给出了一个较清晰的两层解释：标准的 $\text{pass}@k$ 结果支持“覆盖”解释，即强化学习后训练主要提高小采样预算下的采样效率；任务一致和打乱条件下的对比则进一步显示，强化学习后训练的模型具有更强的“元适应”能力，从任务一致的上下文下看到了可测量的额外收益。虽然该结论仍需更大规模实验验证，但它说明第 4.3 节提出的 M_k 指标是可操作的，也为“强化学习后训练可能进一步塑造模型利用上下文进行快速适应的机制”提供了实验层面的初步支持。关于本实验的更多细节，可以参考附录 B。

第五章 总结与展望

5.1 本文工作总结

本文围绕大语言模型“预训练-后训练”这一训练范式，从元学习角度重新理解预训练和强化学习后训练之间的关系。第一章中已经指出，现有研究常常从初始化质量、“覆盖”或高奖励轨迹概率的角度解释强化学习后训练的有效性。这一解释非常重要，因为它说明强化学习后训练未必总是在创造全新的能力，也可能是在提高模型采样到已有正确轨迹的概率。但如果只停留在这个层面，仍然有一些问题没有得到充分揭示：为什么具有相近初始性能的模型在强化学习后训练后可能出现不同提升？为什么有些模型似乎更容易从上下文、反馈或少量经验中调整行为？这些问题提示我们，预训练模型可能不只是一个静态的初始策略，也可能已经形成某种基于上下文的快速适应机制。本文的核心工作，就是围绕这一点，将预训练、上下文学习和强化学习后训练放到同一个元学习视角下重新审视。

第三章主要回答了第一个问题：预训练为什么可能产生元学习能力？本文从任务结构化数据出发，强调真实语言和数学数据并不是完全无结构的词元序列，而是包含大量具有内部一致性的任务片段。任务一致性在这里起到关键作用：当上下文样本和查询样本来自同一个潜在任务时，上下文就包含了关于当前任务的信息；而如果这种关系被打乱，上下文虽然仍然存在，却不再需要被当做支持集使用。在这一设定下，下一词元预测的查询位置预测目标自然具有贝叶斯元预测器的形式。进一步地，线性分类和线性回归中的共享低维结构例子表明，如果不同任务共享某种可迁移结构，预训练阶段就可能学习这种结构；测试时面对新任务，模型只需要利用少量上下文样本识别当前任务的低维参数。因此，预训练的作用不只是记住知识或提高初始准确率，也可能为后续上下文适应提供了一种可复用的表示和机制。

第四章进一步讨论强化学习后训练在这一框架中的位置。按照“覆盖”视

角，强化学习后训练可以被理解为从预训练策略出发的在线策略微调：基模型已经对某些高奖励轨迹分配了非零概率，强化学习通过奖励信号提高这些轨迹的采样概率，从而提升小采样预算（ k ）下的成功率。本文并不否认这一解释，而是在此基础上进一步引入“元适应”视角：如果预训练模型已经是一个上下文元学习器，那么强化学习后训练优化的对象就不只是单个输入下的输出概率，也包括模型如何利用上下文生成任务相关策略。为此，本文定义了任务一致上下文和打乱上下文的总体表现，并引入了“元适应分数” M_k ，将强化学习后训练的收益分解为“覆盖”/采样效率增益和“元适应”增益两部分。通过 KL 正则化策略改进的分析，本文进一步说明，当上下文确实携带奖励相关信息时，强化学习外层优化可以在一阶意义上提高模型利用上下文的能力。

第 4.4 节的实验部分围绕这一理论分解进行了小规模验证。结果显示，RL 模型在小 k 下明显强于基模型，而基模型在较大 k 下仍然具有较强“覆盖”能力；同时，任务一致上下文相对于打乱上下文带来了小幅但稳定的正收益，并且这一收益在强化学习模型上略高于基模型。这个结果虽然不能说明强化学习一定创造了全新的推理能力，但它支持了本文的基本判断：在“覆盖”之外，模型利用上下文的方式也可以成为观察强化学习后训练效果的一个维度。

总的来说，本文试图给出的不是一个完整的新训练算法，而是一个解释框架。“覆盖”解释是必要的，但可能不充分；预训练可能通过任务结构化数据形成上下文适应机制，强化学习后训练则可能在奖励反馈下进一步调整这种机制。通过区分“覆盖”增益和“元适应”增益，本文希望为理解大语言模型两阶段训练范式提供一个更细的视角，也为后续研究更高效、更稳定、更具迁移能力的后训练方法提供一些参考。

5.2 局限性与未来展望

需要承认的是，本文的理论分析仍然建立在较为理想化的设定上。第三章中的线性分类和线性回归模型只能刻画任务共享结构和上下文适应机制中的一部分现象；第四章中的理论分解也采用了抽象的上下文策略和 KL 正则化策略提升，而真实大语言模型的预训练语料、transformer 表示、强化学习优化过程和奖励信号都要复杂得多。因此，本文的理论结果更适合作为理解机制的简化模型，

而不是对真实后训练过程的完整刻画。未来可以进一步考虑更贴近实际模型的设定，例如更一般的非线性任务族、更真实的 transformer 上下文学习机制，以及强化学习训练过程中策略分布如何随训练步数发生变化。更重要的是，本文的理论视角不应只停留在解释层面，而应进一步服务于训练方法的设计：如果预训练确实能够形成某种可迁移的上下文适应机制，那么未来就可以思考如何通过更有结构的预训练数据或训练目标，显式增强模型对任务结构的识别和利用能力。

实验部分也仍然是初步的。本文只使用了一组 7B 模型对，并在 MATH500 的小规模子集上构造任务一致和打乱上下文。由于当前任务一致性主要基于题目类别来构造，同一类别内部仍可能包含差异较大的题型，因此实验中的任务一致条件只是较弱的任务一致性近似。此外，本文提出的 M_k 可能受到 prompt 格式、示例选择、答案解析和采样方差等因素影响。更关键的是，本文实验本质上仍然是对已有模型的评估（evaluation），而不是直接研究预训练或强化学习后训练本身；换言之，它更像是一个用于区分“覆盖”收益和“元适应”收益的学习，而还没有真正检验不同预训练数据结构、后训练算法或训练阶段如何塑造这种适应能力。后续更稳健的实验应当扩大数据规模，引入更多模型和强化学习的检查点，并使用基于检索或模式匹配的方式构造更细粒度的任务一致上下文。

从更长远的角度看，本文只是对“覆盖”之外的强化学习后训练作用机制做了一个初步探索。未来值得进一步研究的问题包括：预训练阶段如何系统性地形成可迁移的上下文适应机制；强化学习后训练是否会在训练过程中逐步增强这种机制；不同奖励形式、KL 约束和数据难度如何影响“覆盖”增益与“元适应”增益之间的平衡。在实践层面，一个更有价值的方向是将本文的“任务一致上下文一打乱上下文”对照从评价协议推进为训练设计原则：例如，在预训练或后训练中显式构造任务一致的上下文回合，或者设计奖励来鼓励模型利用上下文中的任务结构，而不只是提高单个答案的正确率。类似思维链（chain-of-thought）的方法也说明，结构化的中间过程和上下文组织方式可能会显著改变模型的推理与适应行为。若未来能够更清楚地理解并利用这类结构，就有可能指导更有效的后训练算法设计，使强化学习不只是放大已有高奖励轨迹，也能更稳定地提升模型利用上下文、反馈和任务结构进行快速适应的能力。

参考文献

- [1] BROWN T, MANN B, RYDER N, et al. Language models are few-shot learners[J]. Advances in neural information processing systems, 2020, 33: 1877-1901.
- [2] OUYANG L, WU J, JIANG X, et al. Training language models to follow instructions with human feedback[J]. Advances in neural information processing systems, 2022, 35: 27730-27744.
- [3] SHAO Z, WANG P, ZHU Q, et al. Deepseekmath: Pushing the limits of mathematical reasoning in open language models[J]. ArXiv preprint arXiv:2402.03300, 2024.
- [4] GUO D, YANG D, ZHANG H, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning[J]. ArXiv preprint arXiv:2501.12948, 2025.
- [5] CHEN Z, LU R, ZHAO A, et al. Does reinforcement learning really incentivize reasoning capacity in llms beyond the base model?[J]. Advances in Neural Information Processing Systems, 2025, 38: 57654-57689.
- [6] FINN C, ABBEEL P, LEVINE S. Model-agnostic meta-learning for fast adaptation of deep networks[C]// International conference on machine learning. 2017: 1126-1135.
- [7] DUAN Y, SCHULMAN J, CHEN X, et al. Rl ²: Fast reinforcement learning via slow reinforcement learning[J]. ArXiv preprint arXiv:1611.02779, 2016.
- [8] XIE S M, RAGHUNATHAN A, LIANG P, et al. An explanation of in-context learning as implicit bayesian inference[J]. ArXiv preprint arXiv:2111.02080, 2021.

- [9] MAGEN R, VARDI G. Transformers are almost optimal metalearners for linear classification[J]. Advances in Neural Information Processing Systems, 2025, 38: 76619-76654.
- [10] MIN S, LYU X, HOLTZMAN A, et al. Rethinking the role of demonstrations: What makes in-context learning work?[C] // Proceedings of the 2022 conference on empirical methods in natural language processing. 2022: 11048-11064.
- [11] GARG S, TSIPRAS D, LIANG P S, et al. What can transformers learn in-context? a case study of simple function classes[J]. Advances in neural information processing systems, 2022, 35: 30583-30598.
- [12] AKYÜREK E, SCHUURMANS D, ANDREAS J, et al. What learning algorithm is in-context learning? investigations with linear models[J]. ArXiv preprint arXiv:2211.15661, 2022.
- [13] VON OSWALD J, NIKLASSON E, RANDAZZO E, et al. Transformers learn in-context by gradient descent[C] // International Conference on Machine Learning. 2023: 35151-35174.
- [14] ZHANG R, FREI S, BARTLETT P L. Trained transformers learn linear models in-context[J]. Journal of Machine Learning Research, 2024, 25(49): 1-55.
- [15] LAMPINEN A K, CHAN S C, SINGH A K, et al. The broader spectrum of in-context learning[J]. ArXiv preprint arXiv:2412.03782, 2024.
- [16] RIECHERS P M, BIGELOW H R, ALT E A, et al. Next-token pretraining implies in-context learning[J]. ArXiv preprint arXiv:2505.18373, 2025.
- [17] WANG J X, KURTH-NELSON Z, TIRUMALA D, et al. Learning to reinforcement learn[J]. ArXiv preprint arXiv:1611.05763, 2016.
- [18] XU Z, van HASSELT H P, SILVER D. Meta-gradient reinforcement learning[J]. Advances in neural information processing systems, 2018, 31.
- [19] BECK J, VUORIO R, ZHERAN LIU E, et al. A survey of meta-reinforcement learning[J]. ArXiv e-prints, 2023: arXiv-2301.

- [20] SUN W, VEMULA A, BOOTS B, et al. Provably efficient imitation learning from observation alone[C] // International conference on machine learning. 2019: 6036-6045.
- [21] VEMULA A, SONG Y, SINGH A, et al. The virtues of laziness in model-based rl: A unified objective and algorithms[C] // International Conference on Machine Learning. 2023: 34978-35005.
- [22] XIE T, JIANG N, WANG H, et al. Policy finetuning: Bridging sample-efficient offline and online reinforcement learning[J]. Advances in neural information processing systems, 2021, 34: 27395-27407.
- [23] HUANG A, GHAVAMZADEH M, JIANG N, et al. Non-adaptive online finetuning for offline reinforcement learning[C] // Reinforcement Learning Conference. 2024.
- [24] CHANG J D, ZHAN W, OERTELL O, et al. Dataset reset policy optimization for rlhf[J]. ArXiv preprint arXiv:2404.08495, 2024.
- [25] FOSTER D J, MHAMMEDI Z, ROHATGI D. Is a good foundation necessary for efficient reinforcement learning? the computational role of the base model in exploration[J]. ArXiv preprint arXiv:2503.07453, 2025.
- [26] LIU M, DIAO S, LU X, et al. Prorl: Prolonged reinforcement learning expands reasoning boundaries in large language models[J]. Advances in Neural Information Processing Systems, 2026, 38: 17998-18031.
- [27] CHENG J Z, HAO S, LIU T, et al. Revisiting reinforcement learning for llm reasoning from a cross-domain perspective[J]. Advances in Neural Information Processing Systems, 2026, 38.
- [28] ZHANG C, NEUBIG G, YUE X. On the interplay of pre-training, mid-training, and rl on reasoning language models[J]. ArXiv preprint arXiv:2512.07783, 2025.
- [29] ZHU H, ZHANG Z, HUANG H, et al. The path not taken: Rlvr provably learns off the principals[J]. ArXiv preprint arXiv:2511.08567, 2025.

- [30] SOUDRY D, HOFFER E, NACSON M S, et al. The implicit bias of gradient descent on separable data[J]. Journal of Machine Learning Research, 2018, 19(70): 1-57.
- [31] WU J, BRAVERMAN V, LEE J D. Implicit bias of gradient descent for logistic regression at the edge of stability[J]. Advances in Neural Information Processing Systems, 2023, 36: 74229-74256.
- [32] XIE T, FOSTER D J, BAI Y, et al. The role of coverage in online reinforcement learning[J]. ArXiv preprint arXiv:2210.04157, 2022.
- [33] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal policy optimization algorithms[J]. ArXiv preprint arXiv:1707.06347, 2017.
- [34] HU J. Reinforce++: A simple and efficient approach for aligning large language models[J]. ArXiv e-prints, 2025: arXiv-2501.
- [35] YU Q, ZHANG Z, ZHU R, et al. Dapo: An open-source llm reinforcement learning system at scale[J]. Advances in Neural Information Processing Systems, 2026, 38: 113222-113244.
- [36] SUTTON R S, BARTO A G, et al. Reinforcement learning: An introduction[M]. MIT press Cambridge, 1998.
- [37] CHEN F, HUANG A, GOLOWICH N, et al. The Coverage Principle: How Pre-Training Enables Post-Training[J]. ArXiv preprint arXiv:2510.15020, 2025.
- [38] ORABONA F. A modern introduction to online learning[J]. ArXiv preprint arXiv:1912.13213, 2019.
- [39] LI X, ZHANG Y, JIANG N. Beyond State-Wise Mirror Descent: Offline Policy Optimization with Parametric Policies[J]. ArXiv preprint arXiv:2602.23811, 2026.
- [40] WAINWRIGHT M J. High-dimensional statistics: A non-asymptotic viewpoint[M]. Cambridge university press, 2019.
- [41] MOHRI M, ROSTAMIZADEH A, TALWALKAR A. Foundations of machine learning[M]. MIT press, 2018.

致 谢

感谢党和国家的政策支持和发展环境，让我能够自信地在这片土地上成长，也让我无比热爱祖国、相信祖国未来的发展。感谢南京大学、匡亚明学院以及人工智能学院的培养，使我能够接触到许多前沿的学术资源和良好的学术环境，参与各种学术与校园活动，并有机会与不同领域的专家老师交流学习。

感谢科学技术的发展，特别是人工智能前沿技术的发展。作为人工智能专业的学生，我能够切身感受到科学技术对人类生产生活带来的巨大促进作用。近年来，以 ChatGPT 为代表的大语言模型快速发展，也让我更加认识到人工智能领域的广阔前景，并坚定了我未来继续深耕人工智能研究的信心。

感谢赵鹏老师带我进入机器学习理论研究的大门。赵老师带着我阅读了很多书和论文，也向我介绍了国际上顶尖的研究工作和知名研究组。在专业知识、学术品味、科研视野以及人生选择等很多方面，赵老师都给予了我非常多的帮助，我对此不胜感激。在本次毕业论文写作过程中，赵老师也对我的研究思路、论文结构和具体内容给予了很多指导，使我能够不断完善论文。也感谢本科 FML 课题组里的各位师兄，带着我学习了很多新的知识，也帮助我提升了对许多问题的理解和判断。

感谢 UIUC 的 Nan Jiang 老师，在我本科最后一年中给予了我非常专业且切中肯綮的指导，手把手教会我如何更加认真地做学术研究，包括如何思考问题、进行公式推导、撰写论文以及准备会议投稿等。这些训练和指导让我受益很多，也对我未来的科研道路有重要影响。

感谢我的好同学们，何俊渊、黄俊杰、肖冕、陈子墨、李俊纬等。在本科生活中，和同学们的相处与交流给我的生活增添了很多乐趣；在我遇到困难、感到沮丧时，来自同学和朋友的鼓励与支持也帮助我继续向前。也感谢我的家人一直以来对我人生选择的支持与鼓励。正是因为家人的理解和支持，我才能够更加坚定地面对接下来的学习和科研道路。

未来，我将继续保持踏实努力的态度，在新的学习和科研道路上不断进步。

附录 A 正文中定理的证明

A.1 第 3.2 节中定理/命题的证明

证明 (命题 3.2.1 的证明) 记 $Q(\cdot | x_q, S_N) := \mathbb{P}(\cdot | x_q, S_N)$ 为任务一致分布 $\mathcal{P}_{\text{coh}}$ 下的真实条件分布。对任意候选预测分布 $p(\cdot | x_q, S_N)$, 查询损失可以写为

$$\mathcal{L}_{\text{qry}}(p) = \mathbb{E}_{x_q, S_N} \left[\mathbb{E}_{y_q \sim Q(\cdot | x_q, S_N)} [-\log p(y_q | x_q, S_N)] \right].$$

对固定的 (x_q, S_N) , 内层交叉熵可以分解为

$$\mathbb{E}_{y_q \sim Q(\cdot | x_q, S_N)} [-\log p(y_q | x_q, S_N)] = H(Q(\cdot | x_q, S_N)) + \text{KL}(Q(\cdot | x_q, S_N) \| p(\cdot | x_q, S_N)),$$

其中第一项与候选分布 p 无关, 而 KL 散度非负, 并且当且仅当两个分布相等时取零。因此, 在所有条件分布组成的候选类中, $\mathcal{L}_{\text{qry}}(p)$ 的总体最优解必须满足 $p^*(\cdot | x_q, S_N) = Q(\cdot | x_q, S_N) = \mathbb{P}(\cdot | x_q, S_N)$ 对 (x_q, S_N) 几乎处处成立。于是我们有 $p^*(y_q | x_q, S_N) = \mathbb{P}(y_q | x_q, S_N)$ 几乎处处成立。

接下来说明该真实条件分布具有贝叶斯元预测器的形式。在任务一致回合中, 先采样潜在任务 $\tau \sim \mu$, 然后上下文样本和查询样本都由同一任务分布 D_τ 生成, 即 $S_N \sim D_\tau^N$, $(x_q, y_q) \sim D_\tau$ 。因此, 在给定潜在任务 τ 和查询输入 x_q 后, 查询输出 y_q 的条件分布不再依赖上下文样本 S_N , 即 $\mathbb{P}(y_q | x_q, S_N, \tau) = \mathbb{P}_\tau(y_q | x_q)$ 。进一步, 我们有,

$$\begin{aligned} \mathbb{P}(y_q | x_q, S_N) &= \int_{\mathcal{T}} \mathbb{P}(y_q | x_q, S_N, \tau) \mathbb{P}(d\tau | S_N, x_q) \\ &= \int_{\mathcal{T}} \mathbb{P}_\tau(y_q | x_q) \mathbb{P}(d\tau | S_N, x_q), \end{aligned}$$

其中第一个等式由于全概率公式, 第二个等式由于条件独立关系。 $\square$

证明 (命题 3.2.2 的证明) 在打乱回合分布 $\mathcal{P}_{\text{shuf}}$ 下, 上下文样本和查询样本分别由独立采样的任务生成: $\tau_1, \dots, \tau_N, \tau_q \stackrel{\text{i.i.d.}}{\sim} \mu$, $(x_i, y_i) \sim D_{\tau_i}$, $(x_q, y_q) \sim D_{\tau_q}$ 。因此, 整个上下文集合 $S_N = \{(x_i, y_i)\}_{i=1}^N$ 与查询样本 (x_q, y_q) 独立, 即 $S_N \perp (x_q, y_q)$ 。

于是, 联合分布可以分解为 $\mathbb{P}(y_q, x_q, S_N) = \mathbb{P}(y_q, x_q)\mathbb{P}(S_N)$; 同时也有 $\mathbb{P}(x_q, S_N) = \mathbb{P}(x_q)\mathbb{P}(S_N)$ 。因此, 只要条件概率有定义, 就有

$$\mathbb{P}(y_q | x_q, S_N) = \frac{\mathbb{P}(y_q, x_q, S_N)}{\mathbb{P}(x_q, S_N)} = \frac{\mathbb{P}(y_q, x_q)\mathbb{P}(S_N)}{\mathbb{P}(x_q)\mathbb{P}(S_N)} = \mathbb{P}(y_q | x_q).$$

也就是说在 $\mathcal{P}_{\text{shuf}}$ 下, 上下文样本 S_N 在给定 x_q 后不再提供关于 y_q 的额外信息。

另一方面, 由命题 3.2.1 中关于对数损失总体最优解的论证可知, 查询损失的最优预测分布满足 $p^*(y_q | x_q, S_N) = \mathbb{P}(y_q | x_q, S_N)$ 。结合刚刚证明的条件独立关系, 得到 $p^*(y_q | x_q, S_N) = \mathbb{P}(y_q | x_q)$ 。因此, 在打乱回合分布下, 总体最优预测器不需要利用上下文样本 S_N 。 $\square$

证明 (命题 3.2.3 的证明) 首先考虑使用上下文样本 S_N 的贝叶斯最优风险。由命题 3.2.1 中关于对数损失的总体最优性可知, 在所有条件分布 $p(y_q | x_q, S_N)$ 中, 最优解为真实条件分布 $p^*(y_q | x_q, S_N) = \mathbb{P}(y_q | x_q, S_N)$ 。因此,

$$R_N^* = \inf_p \mathbb{E} [-\log p(y_q | x_q, S_N)] = \mathbb{E} [-\log \mathbb{P}(y_q | x_q, S_N)].$$

根据条件熵的定义, 上式等于 $R_N^* = H(y_q | x_q, S_N)$ 。同理, 在不使用上下文样本时, 贝叶斯最优预测器为 $p_0^*(y_q | x_q) = \mathbb{P}(y_q | x_q)$ 。从而,

$$R_0^* = \inf_{p_0} \mathbb{E} [-\log p_0(y_q | x_q)] = \mathbb{E} [-\log \mathbb{P}(y_q | x_q)] = H(y_q | x_q) = .$$

于是根据条件互信息的定义, 贝叶斯层面的上下文增益为

$$\text{CG}^*(N) = R_0^* - R_N^* = H(y_q | x_q) - H(y_q | x_q, S_N) = I(y_q; S_N | x_q). \quad \square$$

A.2 第 3.3 节中定理/命题的证明

本节给出第 3.3 节中线性分类结果的更完整表述和证明梗概。该结果亦可以参考 Magen et al.^[9, Theorem 3.1]。为了严格证明，我们需要下面的规范化条件¹。

假设 A.2.1 给定失败概率 $\delta \in (0, 1)$ 。存在足够大的常数 $C > 1$ ，使得：

1. 训练信号强度满足 $C \log(B/\delta) \leq R^2 \leq d/(C \log^2(B/\delta))$;
2. 环境维度满足 $d \geq C \log^4(B/\delta)$;
3. 每个训练任务的上下文样本数满足 $N \geq C(d/R^2) \vee 1$ 。

为了连接梯度下降训练和最大间隔解，还需要如下标准的隐式偏好结论。

假设 A.2.2 (隐式偏好^[30]) 假设最大间隔问题可行，并且梯度下降使用足够小的固定步长训练对数损失 $\ell(z) = \log(1 + \exp(-z))$ 或指数损失 $\ell(z) = \exp(-z)$ 。令

$$W_{\text{MM}} = \arg \min_A \|A\|_F^2 \quad \text{s.t.} \quad \left(\frac{1}{N} \sum_{i=1}^N y_{\tau,i} x_{\tau,i} \right)^\top A y_{\tau,N+1} x_{\tau,N+1} \geq 1, \quad \forall \tau \in [B].$$

则经过梯度下降不断迭代得到的参数 W_t 在方向上收敛到 W_{MM} ，即存在常数 $c_0 > 0$ 使得 $W_t / \|W_t\|_F \rightarrow c_0 W_{\text{MM}}$ 。

定理 A.2.1 (定理 3.3.1 的正式论述) 在第 3.3 节的设定下，存在普适常数 $C > 1$ 和 $c > 0$ ，使得如果规范化条件（假设 A.2.1）对该 C 成立，则以至少 $1 - \delta$ 的概率，对于训练得到的满足假设 A.2.2 的最大间隔解 W_{MM} ，在新的测试任务上有

$$\mathbb{P}(\text{sign}(\hat{y}(E; W_{\text{MM}})) \neq y_{M+1}) \leq 6 \exp \left(- \frac{c(1 \wedge \sqrt{BR^2/(dk)})}{\log^2(B/\delta)} \left(\sqrt{k} \wedge \tilde{R} \wedge \sqrt{\frac{M \tilde{R}^4}{k}} \right) \right).$$

证明 (基于 Magen et al.^[9] 的证明梗概) 证明的核心思路是：先利用梯度下降在分类损失下的隐式偏好，将训练后的线性 *transformer* 归约为最大间隔解 W_{MM} ；再证明该最大间隔解在共享子空间方向上有足够大的信号响应，同时整体 *Frobenius* 范数不太大；最后在测试任务上将分类间隔分解为信号项 (*signal term*) 和噪声项 (*noise term*)，并用集中不等式控制噪声。

¹ 这些条件主要用于保证训练任务上的若干集中不等式成立。第一条要求训练任务既不能过弱，也不能强到使问题退化；第二、三条用于控制高维高斯噪声和上下文均值估计的偏差。

首先, 由于 $\hat{y}(E; W)$ 对参数 W 是线性的, 对数损失或指数损失下的梯度下降在可分数据上会收敛到 *Frobenius* 范数意义下的最大间隔方向 (假设 A.2.2)。因此, 分析训练后的模型可以转化为分析 W_{MM} 。令 $\hat{w}_\tau = \frac{1}{N} \sum_{i=1}^N y_{\tau,i} x_{\tau,i}$ 。在训练分布下, 由 $x_{\tau,i} = y_{\tau,i} w_\tau + z_{\tau,i}$ 可得 $y_{\tau,i} x_{\tau,i} = w_\tau + y_{\tau,i} z_{\tau,i}$ 。因此 $\hat{w}_\tau$ 是 w_τ 的有噪估计, 并满足 $\mathbb{E}[\hat{w}_\tau | w_\tau] = w_\tau$ 。由于 $w_\tau = U a_\tau$, 训练任务之间共享同一个子空间 $\text{span}(U)$ 。

接下来考虑最大间隔问题。其约束可以写为 $\hat{w}_\tau^\top W_{\text{MM}} y_{\tau,N+1} x_{\tau,N+1} \geq 1$ 对任意任务 $\tau \in [B]$ 成立。在高概率事件上, 训练样本满足若干集中性质: $\|\hat{w}_\tau\|^2$ 与 R^2 同阶, $\|x_{\tau,N+1}\|^2$ 与 d 同阶, 不同任务之间的内积较小, 并且 $\hat{w}_\tau^\top y_{\tau,N+1} x_{\tau,N+1}$ 与 R^2 同阶。这些性质来自高维高斯向量和球面随机向量的标准集中不等式 (如 *Lévy*、*Laurent-Massart* 不等式^[40])。它们保证训练任务之间既有足够的可分性, 又不会因为噪声内积过大而破坏最大间隔的分析。

下面说明这个最大间隔解 W_{MM} 的两个关键性质。第一个性质是它在共享子空间上的迹 (*trace*) 足够大。由最大间隔问题的 *KKT* 条件^[41], W_{MM} 可以写为训练约束方向的非负线性组合, 也即 $W_{\text{MM}} = \sum_{\tau=1}^B \lambda_\tau y_{\tau,N+1} \hat{w}_\tau x_{\tau,N+1}^\top$, 其中 $\lambda_\tau \geq 0$ 。因此我们可以利用最大间隔约束和训练任务之间的近似正交性而推出

$$\sum_{\tau=1}^B \lambda_\tau \gtrsim \frac{1 \wedge BR^2/(dk)}{\log^2(B/\delta)} \frac{k}{R^4}.$$

同时, 由于 $w_\tau \in \text{span}(U)$, 而 $\hat{w}_\tau$ 和 $y_{\tau,N+1} x_{\tau,N+1}$ 在共享子空间上的主导部分均与 w_τ 对齐, 可以进一步得到

$$\text{tr}(U^\top W_{\text{MM}} U) \gtrsim \frac{1 \wedge BR^2/(dk)}{\log^2(B/\delta)} \frac{k}{R^2}.$$

这说明训练得到的最大间隔解必须在共享子空间方向上产生足够强的正响应。最大间隔解的第二个性质的范数不太大。为了证明这一点, 可以构造一个显式可行解。例如, 若用共享子空间投影 $UU^\top$ 作为候选矩阵, 则在高概率事件上可以给出 $\hat{w}_\tau^\top UU^\top y_{\tau,N+1} x_{\tau,N+1} \asymp R^2$ 。因此, 适当缩放后的矩阵 $UU^\top/R^2$ 可以满足最大间隔约束。由于 W_{MM} 是所有可行解中 *Frobenius* 范数最小的一个,

于是得到

$$\|W_{\text{MM}}\|_F \leq \frac{\|UU^\top\|_F}{R^2} = \frac{\sqrt{k}}{R^2}.$$

在训练任务数较少的情形下，可以用训练样本自身构造另一类可行解，从而得到更细的界。综合两种情形，可以写成

$$\|W_{\text{MM}}\|_F \lesssim \left(1 \wedge \sqrt{\frac{BR^2}{dk}}\right) \frac{\sqrt{k}}{R^2} \quad \text{或} \quad \|U^\top W_{\text{MM}} U\|_F \lesssim \left(1 \wedge \sqrt{\frac{BR^2}{dk}}\right) \frac{\sqrt{k}}{R^2}.$$

这说明 W_{MM} 既对共享子空间有足够大的迹，又不会因为范数过大而放大噪声。

现在考虑测试任务。令 $\hat{w} = \frac{1}{M} \sum_{i=1}^M y_i x_i$ 。由于 $x_i = y_i w + z_i$ ，对应的分布可以等价，也即 $\hat{w} \stackrel{d}{=} w + M^{-1/2} z$ ， $y_{M+1} x_{M+1} \stackrel{d}{=} w + z'$ ，其中 $z, z' \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, I_d)$ 。因此测试分类错误事件为 $\{\hat{w}^\top W_{\text{MM}} y_{M+1} x_{M+1} < 0\}$ 。代入上面的分解，得到

$$\hat{w}^\top W_{\text{MM}} y_{M+1} x_{M+1} \stackrel{d}{=} w^\top W_{\text{MM}} w + w^\top W_{\text{MM}} z' + M^{-1/2} z^\top W_{\text{MM}} w + M^{-1/2} z^\top W_{\text{MM}} z'.$$

其中 $w^\top W_{\text{MM}} w$ 是信号项，其余三项是噪声项。证明的目标就是说明信号项以较高概率为正且足够大，而噪声项以较高概率较小。

先考虑信号项。因为 $w = Ua$ 且 $a \sim \text{Unif}(\tilde{R}\mathcal{S}^{k-1})$ ，我们有 $\mathbb{E}[w^\top W_{\text{MM}} w \mid W_{\text{MM}}] = \frac{\tilde{R}^2}{k} \text{tr}(U^\top W_{\text{MM}} U)$ 。进一步，利用前面关于 $\text{tr}(U^\top W_{\text{MM}} U)$ 的下界，可以得到信号项的典型大小至少为

$$\frac{\tilde{R}^2}{k} \text{tr}(U^\top W_{\text{MM}} U) \gtrsim \frac{1 \wedge BR^2/(dk)}{\log^2(B/\delta)} \frac{\tilde{R}^2}{R^2}.$$

利用球面二次型的集中不等式，可以证明 $w^\top W_{\text{MM}} w$ 偏离其均值的概率至多为一个指数项，其指数规模由 $\sqrt{k}$ 、 $\tilde{R}$ 和前面的训练规模因子共同控制。

对于噪声项，可以分别使用高斯二次型或双线性型的尾界：

$$w^\top W_{\text{MM}} z' \mid w, W_{\text{MM}} \sim \mathcal{N}(0, \|W_{\text{MM}}^\top w\|^2),$$

并且其尾概率可以由 $\|W_{\text{MM}}\|_F$ 控制。类似地， $M^{-1/2} z^\top W_{\text{MM}} w$ 也由同样的量控制。最后一项 $M^{-1/2} z^\top W_{\text{MM}} z'$ 是两个独立高斯向量通过矩阵 W_{MM} 形成的双线性型，其尾概率由 $\|W_{\text{MM}}\|_F$ 控制，并且额外带有 $M^{-1/2}$ 的缩放。综合这些尾界，

三项噪声同时小于信号项的常数比例的概率至少为

$$1 - 6 \exp \left(- \frac{c}{\log^2(B/\delta)} \left(1 \wedge \sqrt{\frac{BR^2}{dk}} \right) \left(\sqrt{k} \wedge \tilde{R} \wedge \sqrt{\frac{M \tilde{R}^4}{k}} \right) \right).$$

在该事件上, 测试间隔为正, 因此分类正确。于是得到定理 3.3.1 中的误差上界。□

A.3 第 3.4 节中的定理/命题的证明

证明 (命题 3.4.1 的证明) 首先证明插值解中的最小范数解。由假设可知, 对所有 $w \in \text{span}(U)$ 和所有 $x \in \mathbb{R}^d$, 都有 $w^\top W x = w^\top x$ 。由于任意 $w \in \text{span}(U)$ 都可以写成 $w = Ua$, 其中 $a \in \mathbb{R}^k$, 上式等价于 $a^\top U^\top W x = a^\top U^\top x$ 对所有 $a \in \mathbb{R}^k$ 和 $x \in \mathbb{R}^d$ 成立。因此我们有 $U^\top W = U^\top$ 。

反过来, 如果 $U^\top W = U^\top$, 则对任意 $w = Ua$ 和任意 x , 都有

$$w^\top W x = a^\top U^\top W x = a^\top U^\top x = w^\top x.$$

所以插值约束等价于 $U^\top W = U^\top$ 。

现在令 W 为任意满足 $U^\top W = U^\top$ 的矩阵, 并写成 $W = UU^\top + Z$ 。由于 $U^\top UU^\top = U^\top$, 约束 $U^\top W = U^\top$ 等价于 $U^\top Z = 0$ 。于是 $UU^\top$ 与 Z 在 *Frobenius* 内积下正交, 因为

$$\langle UU^\top, Z \rangle_F = \text{tr}(UU^\top Z^\top) = \text{tr}(U^\top Z^\top U) = \text{tr}((U^\top Z)^\top U) = 0.$$

因此我们得到 $\|W\|_F^2 = \|UU^\top\|_F^2 + \|Z\|_F^2$ 。而由于 $\|UU^\top\|_F^2 = \text{tr}(UU^\top UU^\top) = \text{tr}(UU^\top) = k$, 上式在且仅在 $Z = 0$ 时取到最小值。因此最小 *Frobenius norm* 插值解唯一, 且为 $W^* = UU^\top$ 。□

证明 (定理 3.4.1 的证明) 先证明使用共享结构的预测器的误差。由于 $w \in \text{span}(U)$, 存在 $a \in \mathbb{R}^k$ 使得 $w = Ua$ 。记 $P_U = UU^\top$ 为投影矩阵。对给定的上下文样本, 使用共享结构的预测误差为

$$\hat{y}_q^{\text{meta}} - y_q = \hat{w}_M^\top P_U x_q - w^\top x_q = x_q^\top (P_U \hat{w}_M - w).$$

由于 $x_q \sim \mathcal{N}(0, I_d)$, 有 $\mathbb{E}_{x_q} [(\hat{y}_q^{\text{meta}} - y_q)^2 \mid \hat{w}_M, w] = \|P_U \hat{w}_M - w\|_2^2$ 。因此, 我们得到 $\mathbb{E} [(\hat{y}_q^{\text{meta}} - y_q)^2 \mid w] = \mathbb{E} [\|P_U \hat{w}_M - w\|_2^2 \mid w]$ 。

下面计算右侧。令 $g_i = U^\top x_i$ 。由于 $x_i \sim \mathcal{N}(0, I_d)$ 且 $U^\top U = I_k$, 有 $g_i \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, I_k)$ 。又因为 $w = Ua$, 所以 $y_i = x_i^\top w = x_i^\top Ua = g_i^\top a$ 。于是

$$P_U \hat{w}_M = UU^\top \left(\frac{1}{M} \sum_{i=1}^M y_i x_i \right) = U \left(\frac{1}{M} \sum_{i=1}^M y_i U^\top x_i \right) = U \left(\frac{1}{M} \sum_{i=1}^M g_i g_i^\top a \right).$$

因此, 由于 U 的列正交归一, 我们有

$$\|P_U \hat{w}_M - w\|_2^2 = \left\| U \left(\left(\frac{1}{M} \sum_{i=1}^M g_i g_i^\top - I_k \right) a \right) \right\|_2^2 = \left\| \left(\frac{1}{M} \sum_{i=1}^M g_i g_i^\top - I_k \right) a \right\|_2^2.$$

记 $\xi_i = (g_i g_i^\top - I_k) a$ 。则 $\mathbb{E}[\xi_i] = 0$, 且 ξ_i 相互独立。因此交叉项期望为零, 从而

$$\mathbb{E} \left[\left\| \frac{1}{M} \sum_{i=1}^M \xi_i \right\|_2^2 \right] = \frac{1}{M} \mathbb{E} [\|\xi_1\|_2^2].$$

下面计算 $\mathbb{E}[\|\xi_1\|_2^2]$ 。令 $g \sim \mathcal{N}(0, I_k)$ 为标准高斯分布。由高斯分布的旋转不变性 (*rotational invariance*)¹, 不妨设 $a = \|a\|_2 e_1$ 。于是 $\|g g^\top a - a\|_2^2 = \|a\|_2^2 \|g g_1 - e_1\|_2^2$ 。进一步展开, 计算可得

$$\begin{aligned} \mathbb{E}[\|g g_1 - e_1\|_2^2] &= \mathbb{E}[g_1^2 \|g\|_2^2] - 2\mathbb{E}[g_1^2] + 1 \\ &= \mathbb{E}[g_1^4] + \sum_{j=2}^k \mathbb{E}[g_1^2 g_j^2] - 2 + 1 \\ &= 3 + (k-1) - 2 + 1 = k+1. \end{aligned}$$

因此 $\mathbb{E}[\|\xi_1\|_2^2] = (k+1)\|a\|_2^2 = (k+1)\|w\|_2^2$, 从而 $\mathbb{E}[(\hat{y}_q^{\text{meta}} - y_q)^2 \mid w] = \frac{k+1}{M} \|w\|_2^2$ 。

接下来证明不使用共享结构的 $\hat{y}_q^{\text{single}}$ 的误差。此时 $\hat{y}_q^{\text{single}} - y_q = x_q^\top (\hat{w}_M - w)$ 。由 $x_q \sim \mathcal{N}(0, I_d)$ 可得 $\mathbb{E}_{x_q} [(\hat{y}_q^{\text{single}} - y_q)^2 \mid \hat{w}_M, w] = \|\hat{w}_M - w\|_2^2$ 。又因为 $y_i = x_i^\top w$, 有 $\hat{w}_M - w = M^{-1} \sum_{i=1}^M (x_i x_i^\top - I_d) w$ 。记 $\eta_i = (x_i x_i^\top - I_d) w$, 则 $\mathbb{E}[\eta_i] = 0$ 且 η_i 相

1 所谓高斯分布的旋转不变性: 若 $g \sim \mathcal{N}(0, I_k)$, 则对任意正交矩阵 Q , 都有 $Qg \sim \mathcal{N}(0, I_k)$ 。因此, 任意固定向量 a 都可以通过正交变换转到 $\|a\|_2 e_1$ 的方向, 而不改变相关高斯矩的取值。

互独立，因此

$$\mathbb{E}[(\hat{y}_q^{\text{single}} - y_q)^2 \mid w] = \mathbb{E}[\|\hat{w}_M - w\|_2^2 \mid w] = \frac{1}{M} \mathbb{E}[\|\eta_1\|_2^2 \mid w].$$

令 $x \sim \mathcal{N}(0, I_d)$ 。同样利用旋转不变性，不妨设 $w = \|w\|_2 e_1$ 。于是 $\|(xx^\top - I_d)w\|_2^2 = \|w\|_2^2 \|xx_1 - e_1\|_2^2$ ，并且

$$\begin{aligned} \mathbb{E}[\|xx_1 - e_1\|_2^2] &= \mathbb{E}[x_1^2 \|x\|_2^2] - 2\mathbb{E}[x_1^2] + 1 \\ &= \mathbb{E}[x_1^4] + \sum_{j=2}^d \mathbb{E}[x_1^2 x_j^2] - 2 + 1 \\ &= 3 + (d-1) - 2 + 1 = d + 1. \end{aligned}$$

因此 $\mathbb{E}[\|\eta_1\|_2^2 \mid w] = (d+1)\|w\|_2^2$ ，从而 $\mathbb{E}[(\hat{y}_q^{\text{single}} - y_q)^2 \mid w] = \frac{d+1}{M} \|w\|_2^2$ 。 $\square$

A.4 第 4.2 节中定理/命题的证明

证明 (命题 4.2.1 的证明) 记 $Z = (x, S_N)$ 。按照命题假设，由于策略类包含任意条件分布 $\pi(y \mid x, S_N)$ ，总体目标可以按照给定的 Z 逐点最大化。对任意策略 π ，由条件期望公式可得

$$J(\pi) = \mathbb{E}_{\tau, S_N, x} [\mathbb{E}_{y \sim \pi(\cdot \mid x, S_N)} [r_\tau(x, y)]] = \mathbb{E}_{x, S_N} \left[\mathbb{E}_{\tau \mid x, S_N} [\mathbb{E}_{y \sim \pi(\cdot \mid x, S_N)} [r_\tau(x, y)]] \right].$$

因此，对每一个固定的 (x, S_N) ，我们只需要最大化括号中的条件目标。令 $\bar{r}_{x, S_N}(y) = \mathbb{E}_{\tau \mid x, S_N} [r_\tau(x, y)]$ ，则固定 (x, S_N) 后，条件目标可以写为

$$\mathbb{E}_{\tau \mid x, S_N} [\mathbb{E}_{y \sim \pi(\cdot \mid x, S_N)} [r_\tau(x, y)]] = \mathbb{E}_{y \sim \pi(\cdot \mid x, S_N)} [\bar{r}_{x, S_N}(y)].$$

在离散输出空间中，上式等于 $\sum_y \pi(y \mid x, S_N) \bar{r}_{x, S_N}(y)$ 。这是关于分布 $\pi(\cdot \mid x, S_N)$ 的线性函数，因此其最大值可以由任意一个支持在 $\arg \max_y \bar{r}_{x, S_N}(y)$ 上的分布达

到。于是总体最优策略可以逐点取为

$$\pi^*(\cdot | x, S_N) \in \arg \max_{\pi(\cdot | x, S_N)} \mathbb{E}_{\tau | x, S_N} \mathbb{E}_{y \sim \pi(\cdot | x, S_N)} [r_\tau(x, y)].$$

如果允许确定性策略，则最优策略可以把全部概率质量放在某个最大化 $\bar{r}_{x, S_N}(y)$ 的回答上，即

$$y^*(x, S_N) \in \arg \max_y \mathbb{E}_{\tau | x, S_N} [r_\tau(x, y)].$$

这就证明了命题中的最优上下文策略形式。

最后考虑上下文样本与当前任务无关的情形。若 S_N 在给定 x 后不再提供关于 τ 的额外信息，则 $\mathbb{P}(\tau | x, S_N) = \mathbb{P}(\tau | x)$ 几乎处处成立。因此

$$\mathbb{E}_{\tau | x, S_N} [r_\tau(x, y)] = \mathbb{E}_{\tau | x} [r_\tau(x, y)].$$

此时最优回答只依赖于 x ，而不需要利用 S_N 。因此，在上下文与任务无关时，总体最优策略不需要根据上下文样本进行适应。 $\square$

A.5 第 4.3 节中定理/命题的证明

证明 (定理 4.3.1 的证明) 先证明第一部分。由 $M_k(\pi) = V_k^{\text{coh}}(\pi) - V_k^{\text{shuf}}(\pi)$ 可知，对任意策略 π_{RL} ，有

$$\begin{aligned} V_k^{\text{coh}}(\pi_{\text{RL}}) - V_k^{\text{coh}}(\pi_0) &= V_k^{\text{coh}}(\pi_{\text{RL}}) - V_k^{\text{shuf}}(\pi_{\text{RL}}) + V_k^{\text{shuf}}(\pi_{\text{RL}}) - V_k^{\text{shuf}}(\pi_0) \\ &\quad + V_k^{\text{shuf}}(\pi_0) - V_k^{\text{coh}}(\pi_0) \\ &= (V_k^{\text{shuf}}(\pi_{\text{RL}}) - V_k^{\text{shuf}}(\pi_0)) + (M_k(\pi_{\text{RL}}) - M_k(\pi_0)). \end{aligned}$$

这就得到“覆盖”增益与“元适应”增益的精确分解。

下面证明第二部分。先说明 KL 正则化更新的闭式形式。固定 (x, S_N) ，简记 $\pi_0(y) = \pi_0(y | x, S_N)$ ， $m(y) = m_{\text{coh}}(x, S_N, y)$ 。对任意分布 $\nu \in \Delta(\mathcal{Y})$ ，考虑目标

$$F(\nu) = \sum_y \nu(y) m(y) - \frac{1}{\eta} \sum_y \nu(y) \log \frac{\nu(y)}{\pi_0(y)}.$$

由于 $\pi_0(y) > 0$ ，并且负 KL 项关于 ν 严格凹， F 在概率单纯形上有唯一最大值。引入拉格朗日乘子 λ 处理约束 $\sum_y \nu(y) = 1$ ，一阶条件为

$$m(y) - \frac{1}{\eta} \left(\log \frac{\nu(y)}{\pi_0(y)} + 1 \right) + \lambda = 0.$$

因此存在归一化常数 Z_η ，使得

$$\nu^\star(y) = \frac{\pi_0(y) \exp(\eta m(y))}{Z_\eta}, \quad Z_\eta = \sum_{y'} \pi_0(y') \exp(\eta m(y')).$$

这正是定理中给出的 π_η 。当 $\eta \rightarrow 0$ 时， π_η 连续收敛到 π_0 。接下来计算 $M_k(\pi_\eta)$ 在 $\eta = 0$ 处的导数。仍然固定 (x, S_N) ，记 $\pi_\eta(y) = \pi_0(y) \exp(\eta m(y)) / Z_\eta$ ，直接求导可得

$$\frac{d}{d\eta} \pi_\eta(y) = \pi_\eta(y) \left(m(y) - \mathbb{E}_{y' \sim \pi_\eta} [m(y')] \right).$$

因此，对任意有界函数 $h : \mathcal{Y} \rightarrow \mathbb{R}$ ，有

$$\begin{aligned} \frac{d}{d\eta} \mathbb{E}_{y \sim \pi_\eta} [h(y)] &= \sum_y h(y) \frac{d}{d\eta} \pi_\eta(y) \\ &= \mathbb{E}_{y \sim \pi_\eta} [h(y)m(y)] - \mathbb{E}_{y \sim \pi_\eta} [h(y)] \mathbb{E}_{y \sim \pi_\eta} [m(y)] \\ &= \text{Cov}_{\pi_\eta}(h, m). \end{aligned}$$

令 $\eta = 0$ ，即得到 $\left. \frac{d}{d\eta} \mathbb{E}_{y \sim \pi_\eta} [h(y)] \right|_{\eta=0} = \text{Cov}_{\pi_0}(h, m)$ 。现在固定 (τ, x, S_N) ，对任意 η ，令 $q_\eta(\tau, x, S_N) = \mathbb{E}_{y \sim \pi_\eta(\cdot | x, S_N)} [r_\tau(x, y)]$ 。由第 4.1 节中 $\text{pass}@k$ 的定义，

$$\text{pass}@k(\pi_\eta; \tau, x, S_N) = 1 - (1 - q_\eta(\tau, x, S_N))^k.$$

因为 q_η 关于 η 可微，链式法则给出

$$\left. \frac{d}{d\eta} \text{pass}@k(\pi_\eta; \tau, x, S_N) \right|_{\eta=0} = k(1 - q_0(\tau, x, S_N))^{k-1} \left. \frac{d}{d\eta} q_\eta(\tau, x, S_N) \right|_{\eta=0}.$$

在上面的协方差恒等式中取 $h(y) = r_\tau(x, y)$, 可得

$$\left. \frac{d}{d\eta} q_\eta(\tau, x, S_N) \right|_{\eta=0} = \text{Cov}_{\pi_0}(r_\tau(x, \cdot), m_{\text{coh}}(x, S_N, \cdot) \mid x, S_N).$$

于是对 $c \in \{\text{coh}, \text{shuf}\}$, 有

$$\left. \frac{d}{d\eta} V_k^c(\pi_\eta) \right|_{\eta=0} = k \mathbb{E}_c \left[(1 - q_0^c)^{k-1} \text{Cov}_{\pi_0}(r_\tau(x, \cdot), m_{\text{coh}}(x, S_N, \cdot) \mid x, S_N) \right].$$

由 $M_k(\pi_\eta) = V_k^{\text{coh}}(\pi_\eta) - V_k^{\text{shuf}}(\pi_\eta)$, 两式相减得到

$$\begin{aligned} \left. \frac{d}{d\eta} M_k(\pi_\eta) \right|_{\eta=0} &= k \mathbb{E}_{\text{coh}} \left[(1 - q_0^{\text{coh}})^{k-1} \text{Cov}_{\pi_0}(r_\tau(x, \cdot), m_{\text{coh}}(x, S_N, \cdot) \mid x, S_N) \right] \\ &\quad - k \mathbb{E}_{\text{shuf}} \left[(1 - q_0^{\text{shuf}})^{k-1} \text{Cov}_{\pi_0}(r_\tau(x, \cdot), m_{\text{coh}}(x, S_N, \cdot) \mid x, S_N) \right]. \end{aligned}$$

这证明了任意 k 下的一阶导数公式。下面考虑 $k = 1$ 的化简。此时权重项 $(1 - q_0^c)^{k-1}$ 等于 1。对任务一致分布, 条件在 (x, S_N) 上并使用协方差关于第一个变量的线性性, 有

$$\begin{aligned} &\mathbb{E}_{\text{coh}} \left[\text{Cov}_{\pi_0}(r_\tau(x, \cdot), m_{\text{coh}}(x, S_N, \cdot) \mid x, S_N) \mid x, S_N \right] \\ &= \text{Cov}_{\pi_0} \left(\mathbb{E}_{\text{coh}}[r_\tau(x, \cdot) \mid x, S_N], m_{\text{coh}}(x, S_N, \cdot) \mid x, S_N \right) \\ &= \text{Var}_{\pi_0}(m_{\text{coh}}(x, S_N, \cdot) \mid x, S_N). \end{aligned}$$

同理, 对打乱分布有

$$\begin{aligned} &\mathbb{E}_{\text{shuf}} \left[\text{Cov}_{\pi_0}(r_\tau(x, \cdot), m_{\text{coh}}(x, S_N, \cdot) \mid x, S_N) \mid x, S_N \right] \\ &= \text{Cov}_{\pi_0} \left(\mathbb{E}_{\text{shuf}}[r_\tau(x, \cdot) \mid x, S_N], m_{\text{coh}}(x, S_N, \cdot) \mid x, S_N \right) \\ &= \text{Cov}_{\pi_0}(m_{\text{shuf}}(x, S_N, \cdot), m_{\text{coh}}(x, S_N, \cdot) \mid x, S_N). \end{aligned}$$

将两式代入 $k = 1$ 的导数公式, 得到

$$\left. \frac{d}{d\eta} M_1(\pi_\eta) \right|_{\eta=0} = \mathbb{E}_{\text{coh}} \left[\text{Var}_{\pi_0}(m_{\text{coh}} \mid x, S_N) \right] - \mathbb{E}_{\text{shuf}} \left[\text{Cov}_{\pi_0}(m_{\text{shuf}}, m_{\text{coh}} \mid x, S_N) \right].$$

最后证明严格正的一阶导数会推出严格正的元适应增益。由于回答空间有限，奖励有界，且 π_0 对所有回答有正概率， $\pi_\eta(y | x, S_N)$ 在 $\eta = 0$ 的邻域内关于 η 光滑。因此 $M_k(\pi_\eta)$ 在 $\eta = 0$ 处可微，并且

$$M_k(\pi_\eta) - M_k(\pi_0) = \eta \left. \frac{d}{d\eta} M_k(\pi_\eta) \right|_{\eta=0} + o(\eta).$$

若右侧的一阶导数严格大于 0，则存在 $\eta_0 > 0$ ，使得对所有 $0 < \eta < \eta_0$ ，都有 $M_k(\pi_\eta) > M_k(\pi_0)$ 。□

附录 B 正文中涉及的数据及源代码

本附录补充说明第四章实验中使用的数据构造方式、评估代码、运行参数以及指标计算方法。正文第 4.4 节已经介绍了实验的主要设定和结果，本附录主要记录复现实验所需的实现细节。实验代码主要参考 Chen et al.^[5] 使用的 limit-of-RLVR 仓库¹。具体而言，本文沿用了该仓库中的数学评估流程，包括模型加载、prompt 渲染、vLLM 采样、答案解析和自动判分等部分。本文额外完成的主要工作是构造用于元适应实验的数据文件以及评估。除数据构造和本地路径设置外，采样参数基本保持原仓库默认设定。

B.1 数据来源与三类条件

实验中的查询样例来自 MATH500。每道题包含题面、标准答案、标准解答、题目类别以及难度等级。用于构造少样本上下文的样例来自 MATH 训练集，而不是来自 MATH500 本身，以避免从测试题中抽取上下文样例导致数据泄露。

实验共构造三类条件。第一类是零样本条件，即不加入少样本样例，只保留原始题目和固定解题提示。该条件用于观察基模型和 RL 模型在普通 pass@ k 指标下的差异。第二类是任务一致条件，即在查询样例前加入与其同类别、难度相近、题面长度相近的少样本样例。第三类是打乱条件，即同样加入少样本样例，但这些样例来自与查询样例不同的题目类别，同时仍尽量匹配难度和题面长度。任务一致条件与打乱条件的差值用于构造正文第 4.3 节中的“元适应”分数 M_k 。

在当前实验中，每个查询样例前加入 2 个少样本样例。任务一致条件的候选池由 MATH 训练集中与当前查询样例属于同一类别、且难度等级差不超过 1 的题目组成；打乱条件的候选池由不同类别、但难度等级差不超过 1 的题目组成。随后进一步按照题面长度进行匹配，避免任务一致组和打乱组在 prompt 长度上出现系统性差异。

¹ <https://github.com/LeapLabTHU/limit-of-RLVR>

B.2 Prompt 构造

最初实验曾尝试将完整解答放入少样本样例中，但该版本在基模型上容易出现复读 **prompt**、生成极短无效回答或输出无关文本等问题。这个现象说明，完整解答会给模型带来较强的格式干扰，使实验更像是在测试 **prompt** 鲁棒性，而不是测试模型利用任务一致上下文的能力。因此，最终实验采用只含答案的少样本样例，即每个样例只包含题面和最终答案，不包含完整解题过程。

任务一致条件和打乱条件使用相同的 **prompt** 模板，仅少样本样例的来源不同。模板如下：

```
You will be given a few example math problems with final
↳ answers.
Use the examples only as contextual hints about the
↳ mathematical
topic and format.
Then solve the final problem carefully.

Example 1:
Problem:
...
Final Answer:
\boxed{...}

Example 2:
Problem:
...
Final Answer:
\boxed{...}

Now solve the following problem.
Problem:
...
```

随后原评估流程中的 **qwen** 模板会自动追加固定解题提示：


```
Please reason step by step, and put your final answer within
\boxed{ }.
```

这个设计的目的不是让少样本样例直接给出完整推理过程，而是让它们提供题目类别、答案格式和粗略解题方向等上下文信息。由于本文当前使用的是基于题目类别的任务一致性构造，同一类别内部仍可能包含不同题型，因此这种构造应理解为较弱的任务一致上下文。更细粒度的题型检索或人工标注可以作为后续改进方向。

B.3 评估代码与运行参数

实验使用 `limit-of-RLVR` 仓库中的数学评估脚本：

```
./math/examples/math_eval/math_eval.py.
```

该脚本完成模型加载、数据读取、**prompt** 渲染、**vLLM** 采样、答案解析、自动判分和结果保存。本文评估的模型为基模型 `Qwen2.5-Math-7B` 和 **RL** 模型 `Qwen2.5-Math-7B-Oat-Zero`。二者使用相同的 **prompt** 格式、采样参数和判分流程。实验只进行评估，不重新训练模型。

一个代表性的运行命令及对应参数如下：

```
CUDA_VISIBLE_DEVICES=0,1 python -u \
./math/examples/math_eval/math_eval.py \
--model_name_or_path ./models/Qwen2.5-Math-7B \
--data_names math500_coh_n2_anonly \
--data_dir ./math/examples/math_eval/data \
--output_dir outputs/meta_base_coh_n2_anonly_s100_n16 \
--split test --prompt_type qwen-boxed \
--num_test_sample 100 --max_tokens_per_call 4096 \
--seed 1 --temperature 0.6 --n_sampling 16 --top_p 0.95 \
--start 0 --end -1 --use_vllm --save_outputs --overwrite
```

其中 `--n_sampling 16` 表示每道题采样 16 个完整回答, `--num_test_sample 100` 表示使用 100 道 MATH500 查询样例进行评估; `data_names` 指定当前评估使用的数据文件, 例如任务一致条件下的数据文件或打乱条件下的数据文件; `output_dir` 指定输出目录, 用于保存完整回答、自动判分结果和最终指标。评估 RL 模型时, 只需要将 `model_name_or_path` 替换为 RL 模型的本地路径, 并相应修改输出目录名称。

B.4 输出文件与指标整理

每次评估会生成模型回答、答案解析结果、自动判分结果以及汇总指标。正文第 4.4 节中的表格和图均由这些输出文件整理得到。零样本条件的结果用于绘制普通 $\text{pass}@k$ 曲线; 任务一致条件和打乱条件的结果用于计算经验收益以及“元适应”分数:

$$\widehat{M}_k(\pi) = \widehat{V}_k^{\text{coh}}(\pi) - \widehat{V}_k^{\text{shuf}}(\pi).$$

对基模型和 RL 模型分别计算 $\widehat{M}_k$ 后, 再取差值得到 RL 后训练带来的额外“元适应”增益:

$$\Delta \widehat{M}_k = \widehat{M}_k(\pi_{\text{RL}}) - \widehat{M}_k(\pi_0).$$

原始完整回答通常较长, 且主要用于自动判分和错误检查, 因此本文不在附录中逐条列出。附录仅记录数据来源、prompt 构造、评估脚本和运行参数, 以便复现实验流程。